

Elección discreta: Teoría, estimación y métodos numéricos

Tarea 2

El Colegio de México

Prof. Edwin Muñoz Rodríguez

Alumno: Max Brando Serna Leyva

Contents

1	Pregunta 1	2
1.1	Primer inciso	2
1.2	Segundo inciso	3
1.3	Tercer inciso	4
1.4	Cuarto inciso	4
1.5	Quinto inciso	8

1 Pregunta 1

Considere el modelo el modelo logit condicional usando los datos en `yogurt.csv`. La utilidad representativa es

$$\nu_{nj} = \alpha_j + \beta' x_{nj}$$

donde $x_{nj} = (\text{price}_j, \text{feat}_j)$, y α_j es la constante específica para la alternativa j .

1.1 Primer inciso

Normalice $\alpha_4 = 0$. Argumente por qué con esta normalización el modelo está identificado.

Respuesta: Bajo este escenario, las utilidades para cada alternativa del tipo n se representan en el siguiente modelo como:

$$\begin{aligned} u_{n1} &= \alpha_1 + \beta' x_{n1} + \varepsilon_1 \\ &\vdots \\ u_{n4} &= \alpha_4 + \beta' x_{n4} + \varepsilon_4 \\ &\vdots \\ u_{nj} &= \alpha_j + \beta' x_{nj} + \varepsilon_j \end{aligned}$$

Donde $\alpha_k - \alpha_j = d_{kj}$, $\forall j \neq k$. Esta representación es equivalente a:

$$\begin{aligned} u_{n1} &= \hat{\alpha}_1 + \beta' x_{n1} + \varepsilon_1 \\ &\vdots \\ u_{n4} &= \hat{\alpha}_4 + \beta' x_{n4} + \varepsilon_4 \\ &\vdots \\ u_{nj} &= \hat{\alpha}_j + \beta' x_{nj} + \varepsilon_j \end{aligned}$$

siempre que $\hat{\alpha}_k - \hat{\alpha}_j = d_{kj}$, $\forall j \neq k$. Este hecho implica una imposibilidad para estimar los parámetros $\alpha_j \forall j \in |B|$, dado que existen infinitos valores que resultan en la misma diferencia d_{kj} . Es por ello que **al normalizar, obtenemos:**

$$\begin{aligned} \alpha_4 = 0 &\iff \alpha_k - \alpha_4 = \alpha_k - 0 = d_{k4} \\ &\iff \alpha_k = d_{k4} \end{aligned}$$

Por lo que nuestro modelo se convierte en:

$$\begin{aligned} u_{n1} &= d_{14} + \beta' x_{n1} + \varepsilon_1 \\ &\vdots \\ u_{n4} &= \beta' x_{n4} + \varepsilon_4 \\ &\vdots \\ u_{nj} &= d_{j4} + \beta' x_{nj} + \varepsilon_j \end{aligned}$$

Con este modelo no tenemos el problema anterior de imposibilidad en la estimación, puesto que ahora α_{jk} es igual a d_{j4} y éste es único; por tanto, el modelo está identificado, y d_{j4} se puede interpretar como el impacto promedio que factores no observados tienen sobre la utilidad de la alternativa j con respecto a la alternativa 4.

1.2 Segundo inciso

Estime el modelo usando Máxima Verosimilitud.

- No use ninguna rutina integrada para estimar modelos logit multinomiales, como `mlogit` en R o equivalentes. Puede (y debe) usar rutinas de optimización numérica no lineal de propósito general como `optim` en R o `scipy.optimize` en Python. Recomendando experimentar con diferentes métodos de optimización (`method='...'` en `scipy.optimize`).
- Preste atención a la calidad del código y comentarios. Trate de hacer el código eficiente, elegante, legible y reusable, pues este código sera la base para las siguientes tareas.
- Provea pseudo-código y código.

Queremos estimar

$$\hat{\alpha}_{MLE}, \hat{\beta}_{MLE} = \arg \max_{\alpha, \beta} LL(\alpha, \beta \mid \{(m, j^*(m), s_m)\}_{m=1}^M)$$

donde

$$LL(\alpha, \beta \mid \{(m, j^*(m), s_m)\}_{m=1}^M) = \sum_{m=1}^M \log \left(\frac{e^{\alpha_{j^*(m)} + \beta' x_{mj^*(m)}}}{\sum_{i \in B} e^{\alpha_i + \beta' x_{mi}}} \right)$$

recordando que normalizamos haciendo $\alpha_4 = 0$.

A continuación, proveo el pseudo-código para este ejercicio.

Algorithm 1 Estimación de un Modelo de Logit Condicional

- 1: **Entrada:** Base de datos de yogurt con características y elecciones
 - 2: Cargar los datos desde un archivo CSV
 - 3: Definir número de alternativas $A = 4$
 - 4: Definir conjunto de alternativas disponibles $B = \{1, 2, 3, 4\}$
 - 5: Extraer las características de cada alternativa (precio y publicidad)
 - 6: Construir la matriz de características X con dimensiones $(M \times A \times K)$
 - 7: Determinar la alternativa elegida por cada individuo j^*
 - 8: **function** LOGVEROSIMILITUD(θ, X, j^*, B)
 - 9: Calcular utilidades $v_{jn} = \alpha_j + \beta' X_{m,j}$
 - 10: Calcular probabilidades de elección $P_{j,m} = \frac{e^{v_{j,m}}}{\sum_{i \in B} e^{v_{i,m}}}$ y sumar sobre m
 - 11: Retornar el logaritmo de verosimilitud negativo
 - 12: **end function**
 - 13: **function** ESTIMACIÓNMLE(X, j^*, B)
 - 14: Definir valores iniciales de β y α (con $\alpha_4 = 0$)
 - 15: Minimizar la función de log-verosimilitud con algún método usando `scipy.optimize.minimize`
 - 16: Retornar los valores estimados de β y α
 - 17: **end function**
 - 18: **Ejecutar:** Estimación de parámetros con MLE
 - 19: Guardar los valores de β y α
-

En el teams se encuentra el archivo `.py` con el código.

1.3 Tercer inciso

Reporte los coeficientes estimados.

Parámetro	Estimación de ML
β_1	-37.058
β_2	0.487
α_1	1.388
α_2	0.644
α_3	-3.086
α_4	0.000

1.4 Cuarto inciso

Reporte el error estándar de sus estimados usando:

- Teoría asintótica de primer orden.
- Bootstrap (con 3211 repeticiones). En este caso, además de los errores, grafique la distribución marginal empírica de los estimadores. Provea pseudo-código y código.

Para el primer caso, usaremos la matriz hessiana inversa estimada mediante `scipy.optimize.minimize`. El resultado es el siguiente:

Parámetro	Estimación	Error Est. Asintótico
β_1	-37.058	2.399
β_2	0.487	0.120
α_1	1.388	0.088
α_2	0.644	0.054
α_3	-3.086	0.145
α_4	0.000	0.000

Estimaciones de β y α con errores estándar asintóticos calculados mediante `numdifftools`.

Para el caso con bootstrap, los resultados son:

Parámetro	Estimación	Error Est. Bootstrap
β_1	-37.058	2.377
β_2	0.487	0.133
α_1	1.388	0.087
α_2	0.644	0.055
α_3	-3.086	0.144
α_4	0.000	0.000

Estimaciones de β y α con errores estándar de Bootstrap

Existen diferencias que considero pueden deberse a que el método de optimización utilizado, BFGS, arroja una inversa de la Hessiana aproximada, que según foros de internet no es una aproximación acertada. Para solucionar esto habría que calcular el Hessiano analíticamente e integrarlo a la optimización en Python o calcularlo manualmente. Por facilidad, me quedará con el resultado de BFGS.

A continuación el pseudo-código para la implementación del bootstrap:

Algorithm 2 Bootstrap para estimación de errores estándar

```

1: Entrada: Número de iteraciones  $n\_bootstraps$ , datos  $x$ ,  $j\_star$ , alternativas  $B$ 
2: Salida: Errores estándar de Bootstrap  $boot\_se\_betas$ ,  $boot\_se\_alphas$ 

3: Inicialización:
4: Obtener número de observaciones  $M \leftarrow$  longitud de  $df$ 
5: Crear lista vacía  $resample\_indices$ 

6: Generación de índices de resampling:
7: for  $b = 1$  to  $n\_bootstraps$  do
8:     Seleccionar  $M$  índices aleatorios con reemplazo
9:     Almacenar los índices en  $resample\_indices[b]$ 
10: end for

11: Definir función de Bootstrap: ▷ Estimación por iteración
12: function BOOTSTRAPITERATION( $resample\_idx$ )
13:     Extraer muestra  $x\_boot \leftarrow x[resample\_idx]$ 
14:     Extraer elecciones  $j\_star\_boot \leftarrow j\_star[resample\_idx]$ 
15:     Estimar parámetros  $(\beta\_boot, \alpha\_boot) \leftarrow$  ESTIMATEBETAALPHA( $x\_boot, j\_star\_boot, B$ )
16:     return  $(\beta\_boot, \alpha\_boot)$ 
17: end function

18: Ejecutar el Bootstrap mediante paralelización:
19: Ejecutar BOOTSTRAPITERATION para cada  $resample\_idx$  en  $resample\_indices$ 
20: Guardar resultados en  $results$ 

21: Extraer estimaciones de Bootstrap:
22: Crear matriz  $bootstrap\_betas$  con los valores  $\beta\_boot$  de  $results$ 
23: Crear matriz  $bootstrap\_alphas$  con los valores  $\alpha\_boot$  de  $results$ 

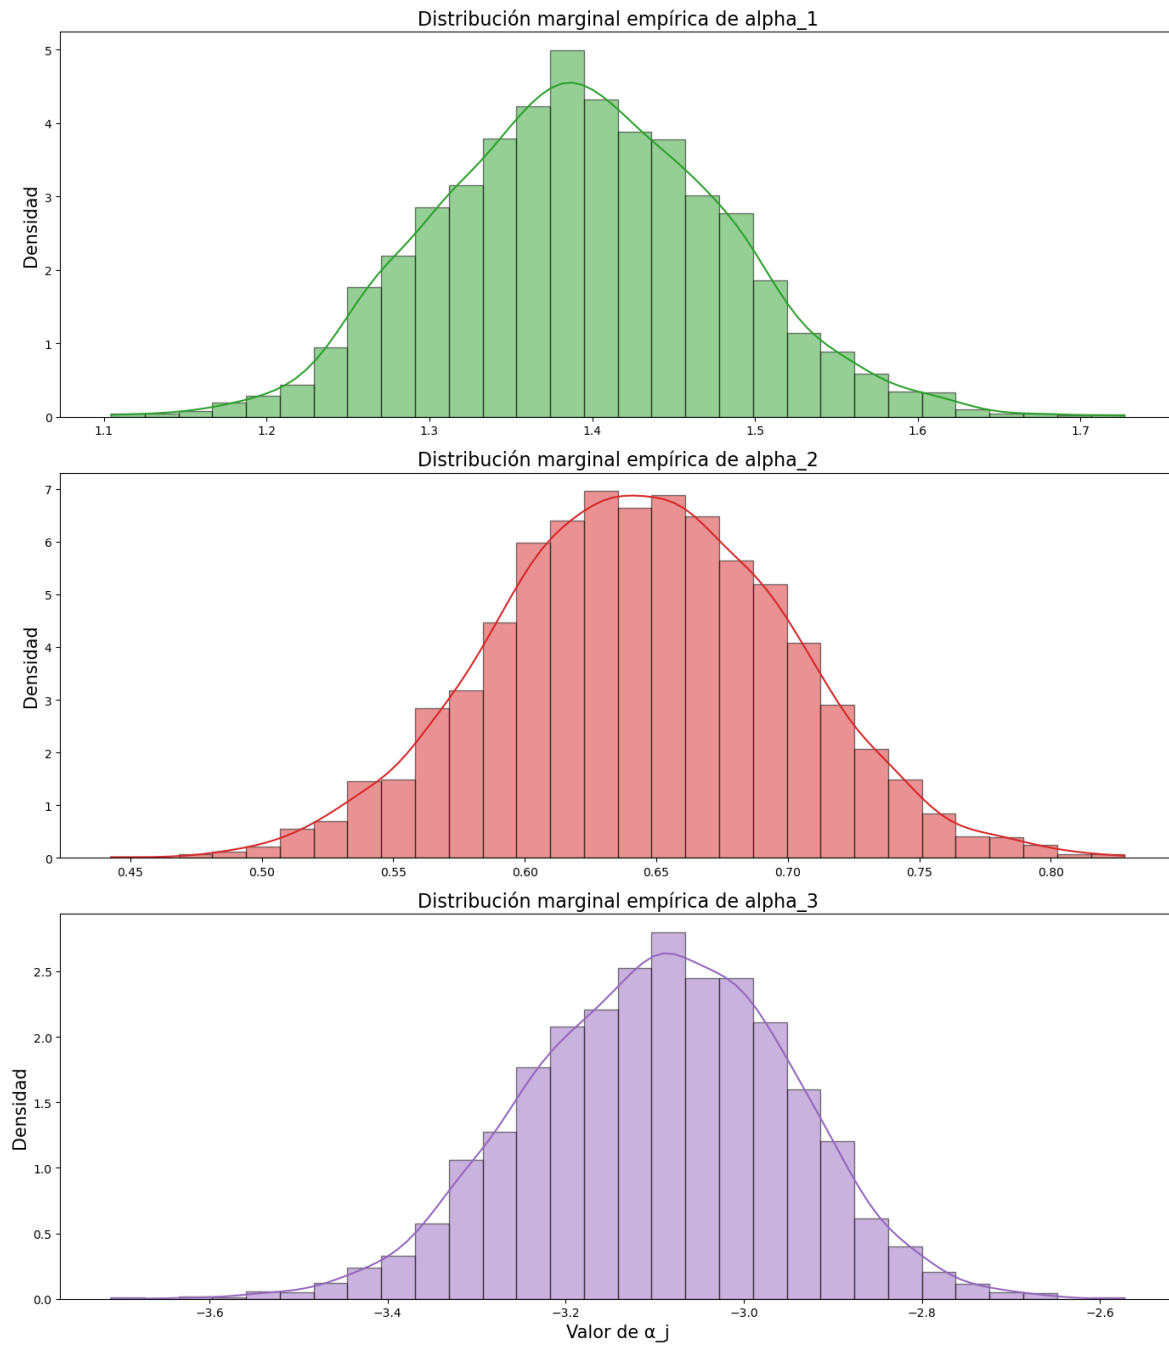
24: Calcular errores estándar de Bootstrap:
25:  $boot\_se\_betas \leftarrow$  desviación estándar de  $bootstrap\_betas$ 
26:  $boot\_se\_alphas \leftarrow$  desviación estándar de  $bootstrap\_alphas$ 

27: Fin del algoritmo.

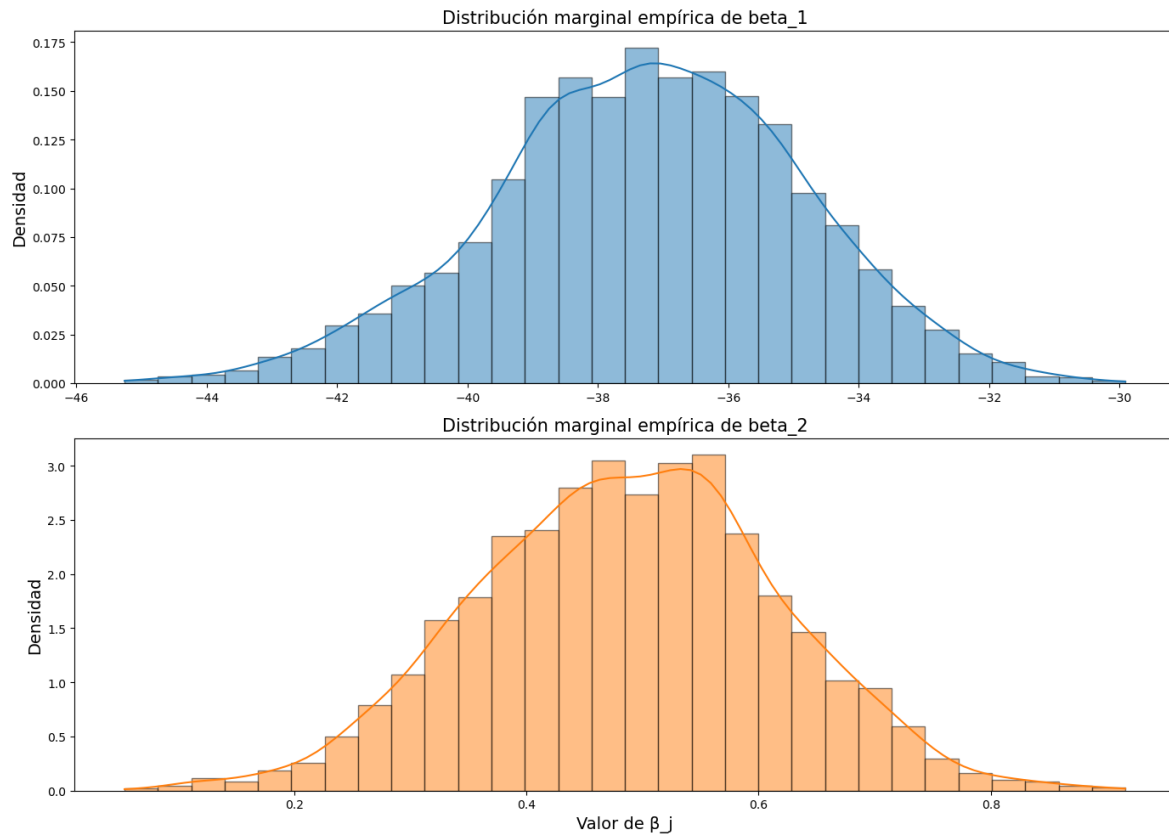
```

En lo sucesivo presento las distribuciones marginales empíricas de los estimadores de ML obtenida mediante bootstrap.

Distribución marginal empírica de los estimadores de β obtenida mediante bootstrap.



Distribución marginal empírica de los estimadores de α obtenida mediante bootstrap.



1.5 Quinto inciso

Calcule las elasticidades precio propias y cruzadas, e interprete los resultados.

Esto se obtiene usando las fórmulas derivadas en la tarea anterior. Los resultados son los siguientes:

	$j = 1$	$j = 2$	$j = 3$	$j = 4$
$j = 1$	-2.701	1.177	0.054	0.659
$j = 2$	1.236	-1.844	0.054	0.659
$j = 3$	1.236	1.177	-1.933	0.659
$j = 4$	1.236	1.177	0.054	-2.288

Elasticidades precio propias (diagonal) y cruzadas (fuera de la diagonal), promediadas entre individuos.

Esta tabla presenta las elasticidades precio cruzadas y propias para cada una de las cuatro alternativas, promediadas entre todas las M observaciones. Dado que la elasticidad propia es negativa para todas las alternativas, nos encontramos ante bienes normales. Además, las elasticidades cruzadas son positivas, lo que implica que son sustitutos entre ellas.