

# Elección discreta: Teoría, estimación y métodos numéricos

## Tarea 4: Mixed logit

El Colegio de México

Prof. Edwin Muñoz Rodríguez

Alumno: Max Brando Serna Leyva

### Índice

1. Instrucciones iniciales	2
2. Inciso 1	3
3. Inciso 2	4
4. Inciso 3	5
5. Inciso 4	6

## 1. Instrucciones iniciales

En esta tarea implementaremos el Mixed logit en nuestra base de datos `yogurt.csv`.

Considere el siguiente modelo de utilidad aleatoria:

$$u_{jm} = \alpha_{jm} + \beta_{mp}price_{jm} + \beta_{mf}feat_{jm} + \varepsilon_{jm} \quad (1.1)$$

donde  $\varepsilon_{jm} \sim Gumbel(0, 1)$  son i.i.d. entre consumidores y productos. Normalice  $\alpha_4 = 0$ .

Asuma que los coeficientes  $\alpha_{jm}$ ,  $j = 1, 2, 3$  así como  $\beta_{mp}, \beta_{mf}$  son aleatorios, distribuidos normales con medias  $\bar{\alpha}_j, \bar{\beta}_p, \bar{\beta}_f$  y matriz de varianzas y covarianzas

$$\Sigma_{5 \times 5} = \begin{bmatrix} \sigma_1^2 & & & & \\ & \sigma_2^2 & & & \\ & & \sigma_3^2 & & \\ & & & \sigma_p^2 & \\ & & & & \sigma_f^2 \end{bmatrix}$$


con todos los términos fuera de la diagonal iguales a cero. Esto es, son independientes.

1. Haga un supuesto sobre la estabilidad de las preferencias de los hogares, y asegúrese de que su modelo sea consistente con dicho supuesto. Para esto, recuerde que la variable `pan.id` es un identificador de hogar.
2. Escriba claramente el modelo que estima, la verosimilitud y la verosimilitud simulada.
3. Para asegurarse de que  $\Sigma_{5 \times 5}$  es definida positiva implemente la descomposición de Cholesky.
4. Reporte las estimaciones y errores estándar para todos los parámetros con  $R = 50$ , usando método de montecarlo. Discuta sus resultados.

## 2. Inciso 1

Revisando la variable `pan.id` nos damos cuenta de que un mismo hogar entra a la base de datos en repetidas ocasiones, lo que significa que **tenemos más de una situación de elección para cada hogar**. La figura 1 muestra un histograma donde se observa el número de situaciones de elección para cada hogar en la muestra.

Figura 1: Histograma de `pan.id`



Esto plantea un problema en cuanto a la caracterización de las preferencias.

Sea  $b_n = (\alpha_{n1}, \alpha_{n2}, \alpha_{n3}, \beta_{np}, \beta_{nf})^\top$ , con  $n = 1, 2, \dots, N$ , donde  $N$  es el número de hogares en la muestra. Si suponemos que en cada situación de elección, tenemos coeficientes distintos, entonces tendríamos que estimar  $b_{n,t_n}$ , donde  $t_n$  sería un subíndice para identificar la situación de elección  $t$  del individuo  $n$ . **Para evitar esto, haremos un supuesto sobre la estabilidad de las preferencias**, en el que para cada individuo  $n$ ,  $b_n$  es constante en toda situación de elección  $t_n$ ; es decir, vamos a suponer que las preferencias de cada individuo son estables a lo largo de todas las situaciones de elección en que se ve envuelto.

### 3. Inciso 2

Podemos reescribir la ecuación 1.1 para obtener **un modelo de mixed logit** sin una representación de coeficientes aleatorios, sino con una de **componentes de error**.<sup>1</sup> Para ello, podemos descomponer el vector de coeficientes aleatorios en una suma entre su vector de medias poblacionales y un vector de componentes de error. Es decir, dado que  $b_n \sim N(\bar{b}, \Sigma)$ , entonces podemos decir que  $b_n = \bar{b} + v_m$ ,  $v_m \sim N(0, 1)$ . Entonces:

$$\begin{aligned} u_{jm} &= \alpha_{jm} + \beta_{mp} price_{jm} + \beta_{mf} feat_{jm} + \varepsilon_{jm} \\ &= b_{jm}^\top z_{jm} + \varepsilon_{jm} \\ &= (\bar{b}_j + v_{jm})^\top z_{jm} + \varepsilon_{jm}, \end{aligned} \quad (3.1)$$

donde  $\bar{b}_j = (\bar{\alpha}_j, \bar{\beta}_p, \bar{\beta}_f)^\top$  y  $z_{jm} = (1, price_{jm}, feat_{jm})^\top$ . De este modo, la **probabilidad de elección incondicional** es

$$\mathbb{P}_{jm} = \int \frac{e^{(\bar{b}_j + v_{jm})^\top z_{jm}}}{\sum_{i \in B} e^{(\bar{b}_i + v_{mi})^\top z_{im}}} f(v_{jm}) dv_{jm}. \quad (3.2)$$

Dada una muestra aleatoria  $\left\{ (m, s_m, j^*(m)) \right\}_{m=1}^M$ , la **función de log-verosimilitud** a optimizar es

$$LL(\bar{b}, \Sigma) = \sum_{m=1}^M \sum_{j \in B} y_{jm} \log \mathbb{P}_{jm}; \quad (3.3)$$

sin embargo, esta función de log-verosimilitud es difícil de implementar, dada la integral múltiple contenida en 3.2. Para solucionar esto, podemos condicionar esta probabilidad de elección en  $v_{jm}$ , con lo que 3.2 se convierte en una **probabilidad de elección condicional**

$$\mathbb{P}_{jm}^{v_{jm}} = \frac{e^{(\bar{b}_j + v_{jm})^\top z_{jm}}}{\sum_{i \in B} e^{(\bar{b}_i + v_{mi})^\top z_{im}}}. \quad (3.4)$$

Además, en clase vimos que si  $\left\{ v_{jm}^r \right\}_{r=1}^R$  son realizaciones del componente de error  $v_{jm}$ , entonces

$$\begin{aligned} \mathbb{P}_{jm} &\approx \mathbb{E}_{v_{jm}} [\mathbb{P}_{jm}^{v_{jm}}] \\ &\approx \frac{1}{R} \sum_{r=1}^R \mathbb{P}_{jm}^{v_{jm}^r} \\ &\equiv \hat{\mathbb{P}}_{jm}^R, \end{aligned} \quad (3.5)$$

por lo que podemos reescribir la función de log-verosimilitud usando 3.5 para obtener una **función de log-verosimilitud simulada**:

$$SLL(\bar{b}, \Sigma) = \sum_{m=1}^M \sum_{j \in B} y_{jm} \log \hat{\mathbb{P}}_{jm}^R. \quad (3.6)$$

En esta tarea, optimizaremos 3.6 para obtener estimados de  $\bar{b}_j$  y  $\Sigma$ .

<sup>1</sup>La única razón siendo que así es como lo practicamos en clase, aunque entiendo que la estimación de un modelo en su forma de coeficientes aleatorios debería ser muy similar.

## 4. Inciso 3

El siguiente paso permite darle mayor estabilidad a la estimación. Nos apoyaremos del siguiente teorema:

**Teorema de la descomposición de Cholesky.** *Sea  $\Sigma$  una matriz real, positiva definida, simétrica y de dimensiones  $n \times n$ . Existe una matriz triangular superior  $\Gamma_{n \times n}$  tal que  $\Sigma = \Gamma^\top \Gamma$ . Además,  $\Gamma$  es única.*

Sea entonces  $\omega \sim N(0, \mathbf{I}_{n \times n})$ . Como sabemos que  $\Sigma$  es una matriz real de dimensión  $n$ , positiva definida y simétrica, entonces por el teorema anterior,  $\exists \Gamma$  tal que  $\Sigma = \Gamma^\top \Gamma$ . Por lo tanto, podemos expresar el componente de error  $v_{jm}$  como

$$v_{jm} = \Gamma^\top \omega_{jm}, \quad (4.1)$$

donde  $\Gamma$  es la matriz de Cholesky asociada a  $\Sigma$ . Por tanto, si  $\left\{ \omega_{jm}^r \right\}_{r=1}^R$  son realizaciones independientes de  $\omega_{jm}$ , entonces usamos 4.1 para obtener

$$\hat{\mathbb{P}}_{jm}^R = \frac{1}{R} \sum_{r=1}^R \frac{e^{(\bar{b}_j + \Gamma^\top \omega_{jm})^\top z_{jm}}}{\sum_{i \in B} e^{(\bar{b}_i + \Gamma^\top \omega_{jm})^\top z_{im}}}. \quad (4.2)$$

## 5. Inciso 4

Nuestro problema de optimización numérica es el siguiente:

$$\begin{aligned} \max_{\bar{b}, \Gamma} \text{SLL}(\bar{b}, \Gamma) &= \sum_{m=1}^M \sum_{j \in B} y_{jm} \log \hat{\mathbb{P}}_{jm}^R, \\ \hat{\mathbb{P}}_{jm}^R &= \frac{1}{R} \sum_{r=1}^R \frac{e^{(\bar{b}_j + \Gamma^\top \omega_{jm})^\top z_{jm}}}{\sum_{i \in B} e^{(\bar{b}_i + \Gamma^\top \omega_{jm})^\top z_{im}}}. \end{aligned}$$

Obteniendo  $\hat{\Gamma}_{\text{SMLE}}$  podemos construir  $\hat{\Sigma}_{\text{SMLE}}$  usando lo que sabemos de la sección 4.

Primero, definiremos tres vectores de condiciones iniciales. La tabla 1 muestra los valores de dichos vectores: el primero es una opción estándar; la segunda corresponde a los parámetros estimados en la tarea anterior, cuando trabajamos con Nested logit; y la tercera, los del Logit condicional.

Tabla 1: Vectores de condiciones iniciales usados en la estimación del modelo Mixed Logit

CI	1. Estándar	2. Nested logit	3. Logit condicional
$\bar{\alpha}_1$	-1.000	-28.196	-37.058
$\bar{\alpha}_2$	-1.000	0.387	0.487
$\bar{\alpha}_3$	-1.000	1.308	1.388
$\bar{\alpha}_4$	0.000	0.000	0.000
$\bar{\beta}_p$	-1.000	0.734	0.644
$\bar{\beta}_f$	-1.000	-1.930	-3.086
$\sigma_p$	0.100	0.100	0.100
$\sigma_f$	0.100	0.100	0.100
$\sigma_1$	0.100	0.100	0.100
$\sigma_2$	0.100	0.100	0.100
$\sigma_3$	0.100	0.100	0.100

Aunado a las estimaciones mediante condiciones iniciales distintas, emplearemos tres métodos de estimación: BFGS, L-BFGS-B y Nelder-Mead. La tabla 2 contiene los resultados, ordenados de izquierda a derecha, de menor a mayor según el valor del AIC. Es posible notar que muchos de las estimaciones son muy similares, y que el modelo ganador se repitió bastante.

Tabla 2: Comparación de modelos Mixed Logit: parámetros estimados

Método	BFGS	BFGS	BFGS	L-BFGS-B	L-BFGS-B	L-BFGS-B	Nelder-Mead	Nelder-Mead	Nelder-Mead
Cond. inic.	CI 3	CI 2	CI 1	CI 2	CI 3	CI 1	CI 3	CI 2	CI 1
$\bar{\alpha}_1$	1.48	1.48	1.48	1.48	1.48	1.48	1.48	1.48	16.37
$\bar{\alpha}_2$	0.67	0.67	0.67	0.67	0.67	0.67	0.67	0.66	22.60
$\bar{\alpha}_3$	-3.45	-3.45	-3.45	-3.45	-3.46	-3.45	-3.45	-3.54	-66.96
$\bar{\alpha}_4$	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
$\bar{\beta}_p$	-40.47	-40.47	-40.47	-40.47	-40.49	-40.49	-40.46	-40.29	-617.21
$\bar{\beta}_f$	-0.04	-0.04	-0.04	-0.04	-0.05	-0.04	-0.04	-0.06	25.59
$\sigma_p$	-2.39	-2.39	-2.39	-2.38	-2.39	-2.40	-2.33	-0.49	-8.65
$\sigma_f$	2.41	2.41	2.41	2.41	2.42	2.42	2.41	2.42	-73.48
$\sigma_1$	-0.07	-0.07	-0.07	-0.06	-0.07	-0.07	-0.07	0.25	-81.58
$\sigma_2$	0.18	0.18	0.18	0.18	0.19	0.19	0.18	-0.15	62.34
$\sigma_3$	0.41	0.41	0.41	0.41	0.41	0.41	0.41	0.56	-42.23
<b>LL</b>	-2647.49	-2647.49	-2647.49	-2647.49	-2647.49	-2647.49	-2647.49	-2648.00	-2703.46
<b>AIC</b>	5314.98	5314.98	5314.98	5314.98	5314.98	5314.98	5314.98	5315.99	5426.93

Finalmente, la tabla 3 muestra los resultados finales junto con los errores estándar de los parámetros calculados asintóticamente. Además, se presenta una comparación con los modelos de Nested logit y Logit condicional. Es posible notar que el modelo de Mixed logit obtenido arroja un AIC menor, lo que sugiere que es superior al resto.

Tabla 3: Comparación de modelos Logit Condicional, Nested Logit y Mixed Logit

Parámetro	Mixed logit	EE	Nested logit	EE	Logit condicional	EE
$\beta_p$	-40.472	3.878	-28.196	3.780	-37.058	2.399
$\beta_f$	-0.045	0.256	0.387	0.102	0.487	0.120
$\alpha_1$	1.483	0.106	1.308	0.079	1.388	0.088
$\alpha_2$	0.666	0.058	0.734	0.070	0.644	0.054
$\alpha_3$	-3.454	0.435	-1.930	0.316	-3.086	0.145
$\alpha_4$	0.000	0.000	0.000	0.000	0.000	0.000
$\lambda_1$	—	—	0.702	0.106	—	—
$\lambda_2$	—	—	0.525	0.120	—	—
$\sigma_p$	-2.387	8.633	—	—	—	—
$\sigma_f$	2.414	0.489	—	—	—	—
$\sigma_1$	-0.065	0.359	—	—	—	—
$\sigma_2$	0.184	0.702	—	—	—	—
$\sigma_3$	0.411	0.871	—	—	—	—
<b>AIC</b>	5314.98		5322.20		5327.11	

*Nota:* Los errores estándar (EE) fueron calculados mediante la teoría asintótica utilizando el hessiano numérico aproximado con `numdifftools`. En el caso del modelo Nested Logit, los parámetros  $\lambda_r$  fueron transformados usando el método delta.