

ECONOMETRIA I
TAREA 8
MAESTRIA EN ECONOMIA, 2023-2025
EL COLEGIO DE MEXICO

Profr. Eneas A. Caldiño García
 Entrega: 13 de marzo de 2024

1. $\left\{ \begin{pmatrix} Y_j \\ X_j \end{pmatrix} \right\}_{j=1}^n$ vectores aleatorios bidimensionales i.i.d.

Para $j = 1, 2, \dots, n$ $\begin{pmatrix} Y_j \\ X_j \end{pmatrix} \sim$ distribución del estudiante bivariada con $v > 2$

grados de libertad.

$$\begin{pmatrix} Y_j \\ X_j \end{pmatrix} \sim St \left(\begin{pmatrix} \mu_Y \\ \mu_X \end{pmatrix}, \begin{pmatrix} \sigma_Y^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_X^2 \end{pmatrix}, v \right) \quad j = 1, 2, \dots, n$$

Se sabe que la función de regresión de Y sobre X es:

$$g: \mathbb{R} \rightarrow \mathbb{R}$$

$$g(x) \equiv E[Y|X=x] = \mu_Y - \frac{\sigma_{XY}}{\sigma_x^2} \mu_x + \frac{\sigma_{XY}}{\sigma_x^2} x$$

La función de cedasticidad es:

$$h: \mathbb{R} \rightarrow \mathbb{R}$$

$$h(x) \equiv \text{var}[Y|X=x] = \frac{v(\sigma_Y^2 - \frac{\sigma_{XY}^2}{\sigma_x^2})}{v-1} [1 + \frac{1}{v\sigma_x^2} (x-\mu_x)^2]$$

i) Graficar la función de regresión $g(x) \equiv E[Y|X=x]$ con $\mu_x = 0$, $\mu_y = 1$,

$$\sigma_x^2 = 1, \sigma_y^2 = 1.64, \sigma_{XY} = -0.8 \text{ y } v = 3.$$

ii) Graficar la función de cedasticidad $h(x) \equiv \text{var}[Y|X=x]$ con $\mu_x = 0$, $\sigma_x^2 = 1$,

$$\sigma_y^2 = 1.64, \sigma_{XY} = -0.8 \text{ y } v = 3.$$

iii) Generar una muestra aleatoria $\left\{ \begin{pmatrix} Y_j \\ X_j \end{pmatrix} \right\}_{j=1}^{120}$ (vectores aleatorios bidimensionales i.i.d.) con distribución

$$\begin{pmatrix} Y_j \\ X_j \end{pmatrix} \sim St \left(\begin{pmatrix} \mu_Y \\ \mu_X \end{pmatrix}, \begin{pmatrix} \sigma_Y^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_X^2 \end{pmatrix}, v \right) \quad j = 1, 2, \dots, 120$$

Graficar en \mathbb{R}^2 la muestra obtenida junto con la curva de regresión.

2. (Ω, F, P) espacio de probabilidad. $\begin{pmatrix} Y \\ X \end{pmatrix}: \Omega \rightarrow \mathbb{R}^2$ vector aleatorio con distribución exponencial bivariada de Gumbel:

$$f_{Y,X}: \mathbb{R}^2 \rightarrow \mathbb{R}$$

$$f_{Y,X}(y, x) = \begin{cases} [(1+\lambda x)(1+\lambda y) - \lambda] e^{-(x+y+\lambda xy)} & \text{si } (y, x) \in (0, \infty) \times (0, \infty) \\ 0 & \text{si } (y, x) \notin (0, \infty) \times (0, \infty) \end{cases}$$

dónde $\lambda \in [0, 1]$.

Se sabe que la función de regresión de Y sobre X es:

$$g: (0, \infty) \rightarrow \mathbb{R}$$

$$g(x) = \frac{1+\lambda+\lambda x}{(1+\lambda x)^2}$$

La función de cedasticidad es:

$$h: \mathbb{R} \rightarrow \mathbb{R}$$

$$h(x) \equiv \text{var}[Y|_{X=x}] = \frac{(1+\lambda+\lambda x)^2 - 2\lambda^2}{(1+\lambda x)^4}$$

i) En un mismo plano graficar las funciones de regresión

$$g(\cdot | \lambda) : (0, \infty) \rightarrow \mathbb{R}$$

correspondientes a $\lambda = 0.01$, $\lambda = 0.5$ y $\lambda = 1$.

ii) En un mismo plano graficar las funciones de cedasticidad

$$h(\cdot | \lambda) : (0, \infty) \rightarrow \mathbb{R}$$

correspondientes a $\lambda = 0.01$, $\lambda = 0.5$ y $\lambda = 1$.

iii) Generar una muestra aleatoria $\left\{ \begin{pmatrix} Y_j \\ X_j \end{pmatrix} \right\}_{j=1}^{120}$ (vectores aleatorios bidimensionales i.i.d.) con distribución exponencial bivariada de Gumbel, con $\lambda = 0.5$

Graficar en un mismo plano la curva de regresión y la muestra obtenida.

3. Generar 30 observaciones i.i.d. $\left\{ \begin{pmatrix} X_{i1} \\ X_{i2} \\ V_i \end{pmatrix} \right\}_{i=1}^{30}$

donde $\begin{pmatrix} X_{i1} \\ X_{i2} \\ V_i \end{pmatrix} \sim N_3 \left(\begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}, \begin{pmatrix} 0.04 & -0.03 & 0 \\ -0.03 & 0.09 & 0.01 \\ 0 & 0.01 & 0.01 \end{pmatrix} \right)$

Generar

$$Y_i = e^{X_{i1}} - \sin(X_{i2}) + V_i \quad i = 1, 2, \dots, 30.$$

Para explicar la variable Y en función de las variables explicativas X_1 y X_2 se propone el "modelo":

$$Y_i = 10 + \pi X_{i1} + e X_{i2} + U_i \quad i = 1, 2, \dots, 30$$

¿Se cumple este modelo? (i.e. ¿Se satisfacen las 30 ecuaciones con los datos

dados?) .

Se propone un segundo "modelo":

$$Y_i = 13 + 3 X_{i1} + 2024 X_{i2} + \varepsilon_i \quad i = 1, 2, \dots, 30$$

(Los coeficientes vienen de que la fecha de entrega de esta tarea es 13/03/2024) .

¿Se cumple este modelo? (i.e. ¿Se satisfacen las 30 ecuaciones con los datos dados?)

4. $\left\{ \begin{pmatrix} Y_j \\ \mathbf{x}_j \end{pmatrix} \right\}_{j=1}^n$ vectores aleatorios de dimensión k i.i.d.

$$\mathbf{y} = \mathbf{x}\mathbf{b} + \mathbf{u}$$

$$Y_j = \alpha + \beta' \mathbf{x}_j \quad j = 1, 2, \dots, n$$

$$Y_j = \alpha + \beta_1 X_{j1} + \beta_2 X_{j2} + \dots + \beta_m X_{jm} + \dots + \beta_{k-1} X_{j,k-1} + U_j \quad j = 1, 2, \dots, n$$

$$\mathbf{y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}_{nx1} ; \quad \mathbf{u} = \begin{pmatrix} U_1 \\ U_2 \\ \vdots \\ U_n \end{pmatrix}_{nx1} ; \quad \mathbf{b} = \begin{pmatrix} \alpha_{1x1} \\ \beta_{(k-1)x1} \end{pmatrix}_{kx1}$$

$$\mathbf{x}_j = \begin{pmatrix} X_{j1} \\ X_{j2} \\ \vdots \\ X_{j,k-1} \end{pmatrix}_{(k-1)x1} ; \quad \mathbf{x}_j = \begin{pmatrix} 1 \\ \mathbf{x}_j \end{pmatrix}_{kx1}$$

$$\mathbf{x} = \begin{pmatrix} 1 & \mathbf{x}'_1 \\ 1 & \mathbf{x}'_2 \\ \vdots & \vdots \\ 1 & \mathbf{x}'_j \\ \vdots & \vdots \\ 1 & \mathbf{x}'_n \end{pmatrix}_{nxk} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1m} & \dots & x_{1,k-1} \\ 1 & x_{21} & x_{22} & \dots & x_{2m} & \dots & x_{2,k-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 1 & x_{j1} & x_{j2} & \dots & x_{jm} & \dots & x_{j,k-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nm} & \dots & x_{n,k-1} \end{pmatrix} = \begin{pmatrix} \mathbf{x}'_1 \\ \mathbf{x}'_2 \\ \vdots \\ \mathbf{x}'_j \\ \vdots \\ \mathbf{x}'_n \end{pmatrix}_{nxk} \quad j = 1, 2, \dots, n$$

i) Demostrar:

a) $\{U_j\}_{j=1}^n$ son v.a.s i.i.d.

b) $\left\{ \begin{pmatrix} U_j \\ \mathbf{x}_j \end{pmatrix} \right\}_{j=1}^n$ son vectores aleatorios i.i.d.

c) $\{\mathbf{x}_j U_j\}_{j=1}^n = \left\{ \begin{pmatrix} x_{j1} U_j \\ x_{j2} U_j \\ \vdots \\ x_{jm} U_j \\ \vdots \\ x_{j,k-1} U_j \end{pmatrix} \right\}_{j=1}^n$ son vectores aleatorios i.i.d.

d) $\text{cov}(U_j, X_{im}) = 0 \quad j = 1, 2, \dots, n; \quad i = 1, 2, \dots, n; \quad i \neq j, \quad m = 1, 2, \dots, k-1$

ii) Demostrar:

$$E[\mathbf{x}' \mathbf{u}] = \mathbf{0}_{k \times 1}$$

$$\Leftrightarrow E[\mathbf{x}_j U_j] = \mathbf{0}_{k \times 1} \quad j = 1, 2, \dots, n$$

$$\Leftrightarrow E(U_j) = 0 \quad y \quad E(\mathbf{x}_j U_j) = \mathbf{0}_{(k-1) \times 1} \quad j = 1, 2, \dots, n$$

$$\Leftrightarrow E(U_j) = 0 \quad y \quad E(X_{ji} U_j) = \mathbf{0}_{1 \times 1} \quad j = 1, 2, \dots, n; \quad i = 1, 2, \dots, k-1$$

$$\Leftrightarrow E(U_j) = 0 \quad y \quad \text{cov}(\mathbf{x}_j, U_j) = \mathbf{0}_{(k-1) \times 1} \quad j = 1, 2, \dots, n$$

$$\Leftrightarrow E(U_j) = 0 \quad y \quad \text{cov}(X_{ji}, U_j) = 0 \quad j = 1, 2, \dots, n; \quad i = 1, 2, \dots, k-1$$

5. Estudiar las sección 2-2 Deriving the Ordinary Least Squares Estimates del capítulo 2 de Wooldridge J.M., *Introductory Econometrics: A Modern Approach*, 5th, 6th or 7th Edition, South-Western CENGAGE Learning.

1. $\left\{ \begin{pmatrix} Y_j \\ X_j \end{pmatrix} \right\}_{j=1}^n$ vectores aleatorios bidimensionales i.i.d.

Para $j = 1, 2, \dots, n$ $\begin{pmatrix} Y_j \\ X_j \end{pmatrix} \sim$ distribución del estudiante bivariada con $v > 2$

grados de libertad.

$$\begin{pmatrix} Y_j \\ X_j \end{pmatrix} \sim St \left(\begin{pmatrix} \mu_y \\ \mu_x \end{pmatrix}, \begin{pmatrix} \sigma_y^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_x^2 \end{pmatrix}, v \right) \quad j = 1, 2, \dots, n$$

Se sabe que la función de regresión de Y sobre X es:

$$g: \mathbb{R} \rightarrow \mathbb{R}$$

$$g(x) \equiv E[Y|X=x] = \mu_y - \frac{\sigma_{xy}}{\sigma_x^2} \mu_x + \frac{\sigma_{xy}}{\sigma_x^2} x$$

La función de cedasticidad es:

$$h: \mathbb{R} \rightarrow \mathbb{R}$$

$$h(x) \equiv \text{var}[Y|X=x] = \frac{v(\sigma_y^2 - \frac{\sigma_{xy}^2}{\sigma_x^2})}{v-1} [1 + \frac{1}{v\sigma_x^2} (x-\mu_x)^2]$$

i) Graficar la función de regresión $g(x) \equiv E[Y|X=x]$ con $\mu_x = 0$, $\mu_y = 1$,

$$\sigma_x^2 = 1, \sigma_y^2 = 1.64, \sigma_{xy} = -0.8 \text{ y } v = 3.$$

$$g(x) = \mu_y - \frac{\sigma_{xy}}{\sigma_x^2} \mu_x + \frac{\sigma_{xy}}{\sigma_x^2} x$$

$$i) g(x) = 1 + \frac{-0.8}{1} x = 1 - \frac{4}{5} x$$



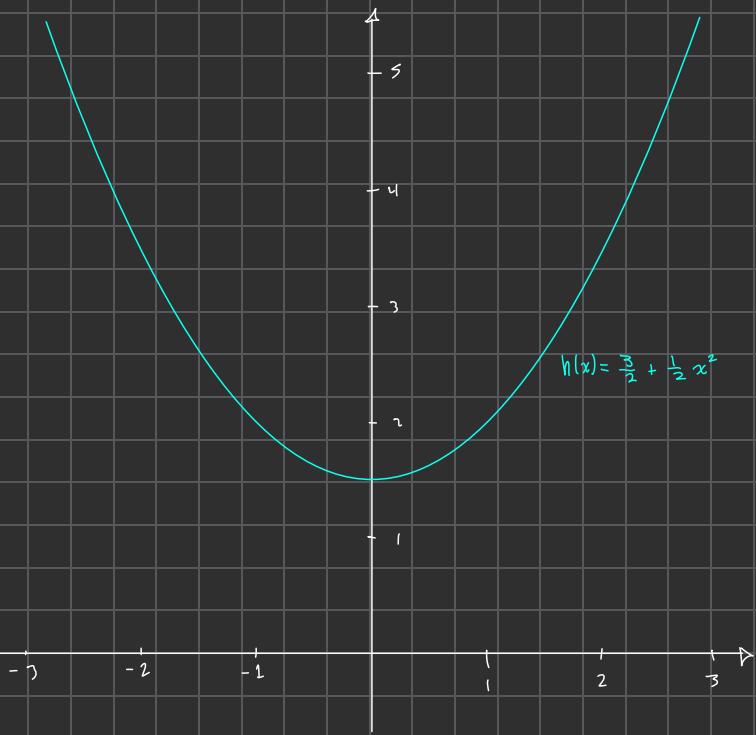
ii) Graficar la función de cedasticidad $h(x) \equiv \text{var}[Y|X=x]$ con $\mu_x = 0$, $\sigma_x^2 = 1$,

$$\sigma_y^2 = 1.64, \sigma_{xy} = -0.8 \text{ y } v = 3.$$

$$h(x) = \frac{\sqrt{\sigma_y^2 - \frac{\sigma_{xy}^2}{\sigma_x^2}}}{\sqrt{v-1}} \left[1 + \frac{1}{\sqrt{v-1}} (x - \mu_x)^2 \right]$$

$$\text{ii) } h(x) = \frac{3(1.64 - \frac{(-0.8)^2}{1})}{3-1} \left[1 + \frac{1}{3(1)} (x-0)^2 \right] = \frac{3(1.64 - 0.64)}{2} \left[1 + \frac{x^2}{3} \right]$$

$$= \frac{3}{2} + \frac{1}{2} x^2$$



iii) Generar una muestra aleatoria $\left\{ \begin{pmatrix} Y_j \\ X_j \end{pmatrix} \right\}_{j=1}^{120}$ (vectores aleatorios bidimensionales i.i.d.) con distribución

$$\begin{pmatrix} Y_j \\ X_j \end{pmatrix} \sim St \left(\begin{pmatrix} \mu_Y \\ \mu_X \end{pmatrix}, \begin{pmatrix} \sigma_y^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_x^2 \end{pmatrix}, v \right) \quad j = 1, 2, \dots, 120$$

Graficar en \mathbb{R}^2 la muestra obtenida junto con la curva de regresión.



Usaremos la librería `mvtnorm` para generar los datos; específicamente la función `rmvt`.

```
library(mvtnorm)
n <- 120
medias <- c(1,0)
df <- 3
Sigma <- matrix(c(1.64, -0.8, -0.8, 1), ncol = 2)*((df-2)/df)
Z <- rep(medias, each = n) + rmvt(n, sigma = Sigma, df = 3)
Z <- data.frame(Z)
names(Z) <- c("Y", "X")
```

Comprobamos las medias de los datos muestrados:

```
round(colMeans(Z), 2)
```

```
##      Y      X
## 0.89 0.07
```

Y la varianza:

```
round(var(Z), 2)
```

```
##          Y      X
## Y  1.58 -0.86
## X -0.86  0.89
```

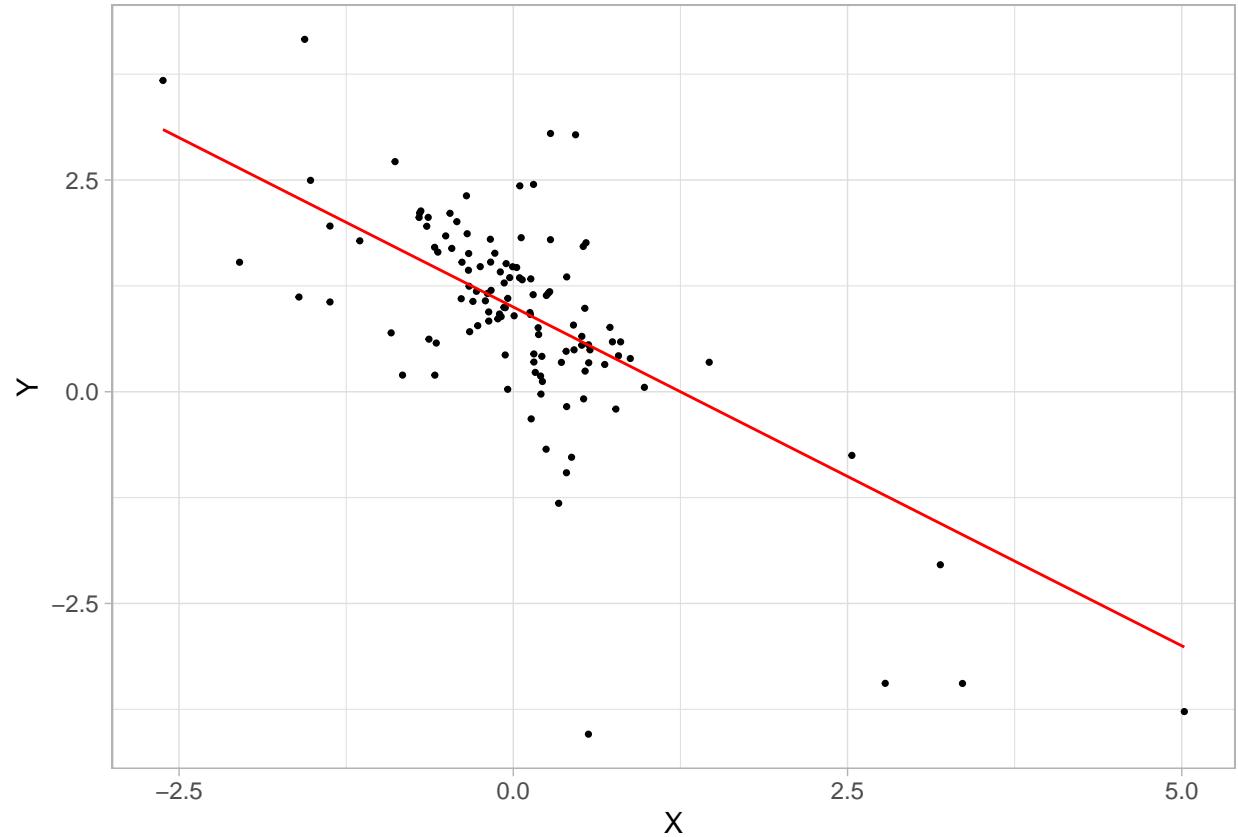
Dada la reducida muestra, los parámetros calculados pueden no ser iguales a los especificados, pero se deben asemejar, como puede verse.

La curva de regresión es: $g(X) = 1 - \frac{4}{5}X$

```
g <- 1-(4/5)*Z$X
```

Graficando los datos simulados y la curva de regresión:

```
library(ggplot2)
datos <- data.frame(Z, g)
names(datos)[3] <- c("g")
ggplot(data = datos) +
  geom_point(aes(x = X, y = Y),
             size = 0.6) +
  geom_line(aes(x = X, y = g),
            col = "red") +
  theme_light()
```



2. (Ω, \mathcal{F}, P) espacio de probabilidad. $\begin{pmatrix} Y \\ X \end{pmatrix}: \Omega \rightarrow \mathbb{R}^2$ vector aleatorio con

distribución exponencial bivariada de Gumbel:

$$f_{Y,X}: \mathbb{R}^2 \rightarrow \mathbb{R}$$

$$f_{Y,X}(y, x) = \begin{cases} [(1+\lambda x)(1+\lambda y)-\lambda] e^{-(x+y+\lambda xy)} & \text{si } (y, x) \in (0, \infty) \times (0, \infty) \\ 0 & \text{si } (y, x) \notin (0, \infty) \times (0, \infty) \end{cases}$$

donde $\lambda \in [0, 1]$.

Se sabe que la función de regresión de Y sobre X es:

$$g: (0, \infty) \rightarrow \mathbb{R}$$

$$g(x) = \frac{1+\lambda+\lambda x}{(1+\lambda x)^2}$$

La función de cedasticidad es:

$$h: \mathbb{R} \rightarrow \mathbb{R}$$

$$h(x) \equiv \text{var}[Y|_{X=x}] = \frac{(1+\lambda+\lambda x)^2 - 2\lambda^2}{(1+\lambda x)^4}$$

i) En un mismo plano graficar las funciones de regresión

$$g(\cdot | \lambda): (0, \infty) \rightarrow \mathbb{R}$$

correspondientes a $\lambda = 0.01$, $\lambda = 0.5$ y $\lambda = 1$.

$$\begin{aligned} f_{Y|X}(y|x) &= \left[(1+\lambda x)(1+\lambda y)-\lambda \right] e^{-(x+y+\lambda xy)} \\ &= \left[1 + \lambda y + \lambda x + \lambda^2 xy - \lambda \right] e^{-(x+y+\lambda xy)} \end{aligned}$$

$$\begin{aligned} F_{Y|X}(x) &= \int_0^\infty \left[1 + \lambda y + \lambda x + \lambda^2 xy - \lambda \right] e^{-(x+y+\lambda xy)} dy \\ &= \int_0^\infty e^{-\lambda y} + \lambda y e^{-\lambda y} + \lambda x e^{-\lambda y} dy \end{aligned}$$

Generemos los datos de la distribución utilizando la siguiente función, basada en la idea de que X sigue una distribución exponencial y que $Y|X$ sigue una distribución gamma. Se sigue la siguiente estrategia para muestrear¹:

1. Muestreamos X de una distribución exponencial.
2. Muestreamos Y condicionada en X

Entonces, para el caso donde $\lambda = 0.5$

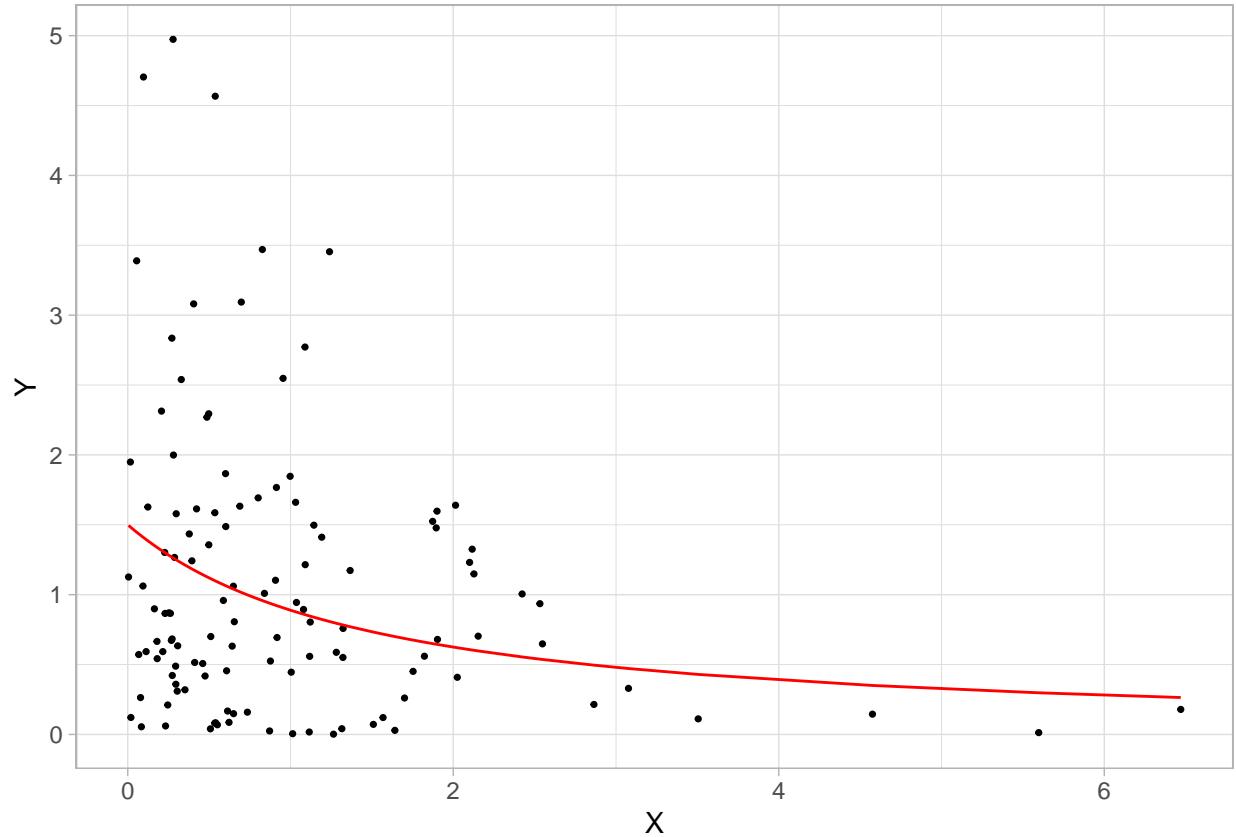
```
rGBVE <- function(n, alpha1, alpha2, lambda) {
  x1 <- rexp(n, alpha1)
  alpha12 <- alpha1*alpha2
  pprod <- alpha12*lambda
  C <- exp(alpha1*x1)
  A <- (alpha12 - pprod + pprod*alpha1*x1)/C
  B <- (pprod*alpha2 + pprod^2*x1)/C
  D <- alpha2 + pprod*x1
  wExp <- A/D
  wGamma <- B/D^2
  data.frame(x1, x2 = rgamma(n, (runif(n) > wExp/(wExp + wGamma)) + 1, D))
}

n <- 120
lmda <- 0.5
Z <- rGBVE(n = n, alpha1 = 1, alpha2 = 1, lambda = lmda)
names(Z) <- c("X", "Y")
```

La gráfica de los datos contra su regresión es:

```
g <- function(x, lambda) {
  (1+lambda+lambda*x)/(1+lambda*x)^2
}
datos <- data.frame(Z, g(Z$X, lambda = lmda))
names(datos) <- c("X", "Y", "g")
ggplot(data = datos) +
  geom_point(aes(x = X, y = Y),
             size = 0.6) +
  geom_line(aes(x = X, y = g),
            col = "red") +
  theme_light()
```

¹Basado en <https://stackoverflow.com/questions/71176416/how-to-simulate-data-from-gumbel-bivariate-exponential-distribution>



Generar 30 observaciones i.i.d. $\left\{ \begin{pmatrix} X_{i1} \\ X_{i2} \\ V_i \end{pmatrix} \right\}_{i=1}^{30}$ donde $\begin{pmatrix} X_{i1} \\ X_{i2} \\ V_i \end{pmatrix} \sim N_3 \left(\begin{pmatrix} 1 \\ 2 \\ 0 \end{pmatrix}, \begin{pmatrix} 0.04 & -0.03 & 0 \\ -0.03 & 0.09 & 0.01 \\ 0 & 0.01 & 0.01 \end{pmatrix} \right)$

```
n <- 30
medias <- c(1,2,0)
Sigma <- matrix(c(0.04, -0.03, 0, -0.03, 0.09, 0.01, 0, 0.01, 0.01), ncol = 3)
Z <- rmvnorm(n, mean = medias, sigma = Sigma)
Z <- data.frame(Z)
names(Z) <- c("X1", "X2", "V")
```

Podemos ver que la media de los datos muestrados se asemeja a la especificada:

```
round(colMeans(Z), 2)
```

```
##   X1     X2      V
## 0.99 2.07 0.01
```

Y su matriz de varianza-covarianza:

```
round(var(Z), 3)
```

```
##       X1      X2      V
## X1  0.039 -0.032 -0.003
## X2 -0.032  0.075  0.005
## V  -0.003  0.005  0.007
```

Generar

$$Y_i = e^{X_{i1}} - \sin(X_{i2}) + V_i \quad i = 1, 2, \dots, 30$$

```
Y <- exp(Z$X1) - sin(Z$X2) + Z$V
```

Para explicar la variable Y en función de las variables explicativas X_1 y X_2 se propone el “modelo”:

$$Y_i = 10 + \pi X_{i1} + e X_{i2} + U_i, \text{ con } i = 1, 2, \dots, 30$$

```
g1 <- 10 + pi*Z$X1 + exp(1)*Z$X2
U <- Y - g1
Ymodel1 <- g1+U
```

¿Se cumple este modelo? (i.e. ¿Se satisfacen las 30 ecuaciones con los datos)

La respuesta a esta pregunta es **sí**, debido a que, a pesar de que quizás no es el mejor modelo, existen $U_1, U_2, U_3, \dots, U_{30}$ tales que hacen que se cumplan las 30 ecuaciones del vector $Ymodel1$, es decir, ocurre que $Y_i = Ymodel1_i \quad \forall i \in \{1, 2, \dots, 30\}$

```
data.frame(Y,Ymodel1,g1,U)
```

```
##          Y    Ymodel1      g1          U
## 1  1.7884208 1.7884208 18.26531 -16.47688
## 2  1.2878967 1.2878967 18.71571 -17.42781
## 3  1.5039825 1.5039825 19.04973 -17.54575
## 4  1.5469401 1.5469401 18.80553 -17.25859
## 5  1.4030178 1.4030178 19.08179 -17.67877
## 6  1.8192765 1.8192765 17.72652 -15.90724
## 7  1.9581314 1.9581314 18.23897 -16.28084
## 8  2.5842788 2.5842788 19.51555 -16.93127
## 9  2.1152657 2.1152657 19.54978 -17.43452
## 10 2.5914916 2.5914916 19.56146 -16.96996
## 11 2.1551966 2.1551966 19.59259 -17.43739
## 12 2.6205560 2.6205560 18.81469 -16.19413
## 13 2.9480458 2.9480458 19.30512 -16.35707
## 14 0.8715154 0.8715154 17.72907 -16.85756
## 15 2.0676019 2.0676019 18.92516 -16.85756
## 16 1.9940734 1.9940734 18.24967 -16.25559
## 17 1.6363613 1.6363613 18.92274 -17.28637
## 18 1.7214821 1.7214821 17.04938 -15.32790
## 19 2.0713315 2.0713315 18.87721 -16.80588
## 20 2.0202826 2.0202826 18.55541 -16.53512
## 21 2.1093777 2.1093777 19.45466 -17.34528
## 22 1.6713971 1.6713971 17.92193 -16.25053
## 23 2.0605541 2.0605541 18.96785 -16.90729
## 24 1.6809899 1.6809899 18.43920 -16.75821
## 25 2.1923240 2.1923240 18.54016 -16.34783
## 26 1.3165268 1.3165268 18.37938 -17.06285
## 27 2.0775279 2.0775279 19.31715 -17.23963
## 28 1.9234088 1.9234088 19.42126 -17.49786
## 29 1.7089578 1.7089578 18.64186 -16.93290
## 30 1.8767981 1.8767981 18.77788 -16.90108
```

Se propone un segundo modelo:

$$Y_i = 13 + 3X_{i1} + 2024X_{i2} + \epsilon_i, \text{ con } i = 1, 2, \dots, 30$$

```
g2 <- 13 + 3*Z$X1 + 2024*Z$X2
epsilon <- Y - g2
Ymodel2 <- g2+epsilon
```

¿Se cumple este modelo? (i.e. ¿Se satisfacen las 30 ecuaciones con los datos)

La respuesta es nuevamente **sí**, por la misma razón que el modelo anterior: existen $\epsilon_1, \epsilon_2, \dots, \epsilon_{30}$ que hacen que las 30 ecuaciones se cumplan; es decir, ocurre que $Y_i = Y_{\text{model2}}_i \forall i \in \{1, 2, \dots, 30\}$:

```
data.frame(Y, Ymodel2, g2, epsilon)
```

```
##          Y    Ymodel2      g2    epsilon
## 1  1.7884208 1.7884208 3885.691 -3883.902
## 2  1.2878967 1.2878967 4976.302 -4975.014
## 3  1.5039825 1.5039825 5031.823 -5030.319
## 4  1.5469401 1.5469401 4591.496 -4589.949
## 5  1.4030178 1.4030178 5348.670 -5347.267
## 6  1.8192765 1.8192765 3233.600 -3231.781
## 7  1.9581314 1.9581314 3703.053 -3701.095
## 8  2.5842788 2.5842788 4341.297 -4338.713
## 9  2.1152657 2.1152657 4841.780 -4839.665
## 10 2.5914916 2.5914916 4161.874 -4159.282
## 11 2.1551966 2.1551966 4649.196 -4647.040
## 12 2.6205560 2.6205560 3624.469 -3621.848
## 13 2.9480458 2.9480458 3689.284 -3686.336
## 14 0.8715154 0.8715154 4646.504 -4645.633
## 15 2.0676019 2.0676019 4132.454 -4130.386
## 16 1.9940734 1.9940734 3720.147 -3718.153
## 17 1.6363613 1.6363613 4585.128 -4583.492
## 18 1.7214821 1.7214821 2923.309 -2921.587
## 19 2.0713315 2.0713315 4195.861 -4193.789
## 20 2.0202826 2.0202826 3788.968 -3786.947
## 21 2.1093777 2.1093777 4704.887 -4702.777
## 22 1.6713971 1.6713971 3575.022 -3573.351
## 23 2.0605541 2.0605541 4268.111 -4266.050
## 24 1.6809899 1.6809899 4177.740 -4176.059
## 25 2.1923240 2.1923240 3646.717 -3644.524
## 26 1.3165268 1.3165268 4519.882 -4518.566
## 27 2.0775279 2.0775279 4437.800 -4435.722
## 28 1.9234088 1.9234088 4558.127 -4556.204
## 29 1.7089578 1.7089578 4216.259 -4214.550
## 30 1.8767981 1.8767981 4117.488 -4115.611
```

$$4. \left\{ \begin{pmatrix} Y_j \\ X_j \end{pmatrix}_{j=1}^n \right\} \text{ vectores aleatorios de dimensión } k \text{ i.i.d.}$$

$$\mathbf{Y} = \mathbf{X}\mathbf{b} + \mathbf{U}$$

$$Y_j = \alpha + \beta' \mathbf{x}_j \quad j = 1, 2, \dots, n$$

$$Y_j = \alpha + \beta_1 X_{j1} + \beta_2 X_{j2} + \dots + \beta_m X_{jm} + \dots + \beta_{k-1} X_{jk-1} + U_j \quad j = 1, 2, \dots, n$$

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}_{nx1} ; \quad \mathbf{U} = \begin{pmatrix} U_1 \\ U_2 \\ \vdots \\ U_n \end{pmatrix}_{nx1} ; \quad \mathbf{b} = \begin{pmatrix} \alpha_{1x1} \\ \beta_{(k-1)x1} \end{pmatrix}_{kx1}$$

$$\mathbf{x}_j = \begin{pmatrix} X_{j1} \\ X_{j2} \\ \vdots \\ X_{jk-1} \end{pmatrix}_{(k-1)x1} ; \quad \mathbf{x}_j = \begin{pmatrix} 1 \\ \mathbf{x}_j \end{pmatrix}_{kx1} \quad \{X_j\}$$

$$\mathbf{X} = \begin{pmatrix} 1 & \mathbf{x}'_1 \\ 1 & \mathbf{x}'_2 \\ \vdots & \vdots \\ 1 & \mathbf{x}'_j \\ \vdots & \vdots \\ 1 & \mathbf{x}'_n \end{pmatrix}_{nxk} = \begin{pmatrix} 1 & X_{11} & X_{12} & \dots & X_{1m} & \dots & X_{1,k-1} \\ 1 & X_{21} & X_{22} & \dots & X_{2m} & \dots & X_{2,k-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 1 & X_{j1} & X_{j2} & \dots & X_{jm} & \dots & X_{jk-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \dots & X_{nm} & \dots & X_{n,k-1} \end{pmatrix} = \begin{pmatrix} \mathbf{x}'_1 \\ \mathbf{x}'_2 \\ \vdots \\ \mathbf{x}'_j \\ \vdots \\ \mathbf{x}'_n \end{pmatrix}_{nxk} \quad j = 1, 2, \dots, n$$

i) Demostrar:

a) $\{U_j\}_{j=1}^n$ son v.a.s i.i.d.

Notemos que si $\mathbf{Y} = \mathbf{X}\mathbf{b} + \mathbf{U} \Rightarrow \mathbf{U} = \mathbf{Y} - \mathbf{X}\mathbf{b}$.

Si consideramos el elemento j -ésimo de \mathbf{U} :

$$\Rightarrow U_j = Y_j - \alpha - \beta^T X_j = Y_j - \beta^T X_j - \alpha = (1, -\beta^T) \begin{pmatrix} Y_j \\ X_j \end{pmatrix} - \alpha$$

$\Rightarrow U_j$ es una transformación lineal de $\begin{bmatrix} Y_j \\ X_j \end{bmatrix}$.

$\Rightarrow U_j$ es una transformación BORELIANA del vector aleatorio $\begin{bmatrix} Y_j \\ X_j \end{bmatrix}$

$\Rightarrow \{U_j\}_{j=1}^n$ son transformaciones boreelianas de los vectores aleatorios i.i.d. $\{\begin{pmatrix} Y_j \\ X_j \end{pmatrix}\}_{j=1}^n$

En clase se vio que transformaciones boreelianas de vec. aleatorios independientes, son independientes.

Además, como $\{\begin{pmatrix} Y_j \\ X_j \end{pmatrix}\}_{j=1}^n$ son idénticamente distribuidos y la transformación boreiana es la misma $\forall j$, $\{U_j\}_{j=1}^n$ tmb. son idénticamente distribuidos.

∴ $\{U_j\}_{j=1}^n$ son variables aleatorias independientes

b) $\left\{ \begin{pmatrix} U_j \\ X_j \end{pmatrix} \right\}_{j=1}^n$ son vectores aleatorios i.i.d.

Sea $Z_j = \begin{pmatrix} Y_j \\ X_j \end{pmatrix}$. Del inciso a) vimos que:

$$Z_j = \begin{pmatrix} Y_j - \beta^T X_j - \alpha \\ X_j \end{pmatrix} = \begin{bmatrix} Y_j - \beta^T X_j - \alpha \\ X_{j1} \\ X_{j2} \\ \vdots \\ X_{j, k-1} \end{bmatrix} = \begin{bmatrix} Y_j \\ X_{j1} \\ X_{j2} \\ \vdots \\ X_{j, k-1} \end{bmatrix} + \begin{bmatrix} -\beta^T X_j - \alpha \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$= \begin{bmatrix} Y_j \\ X_j \end{bmatrix} + \begin{bmatrix} -\beta^T X_j \\ 0_{k-1} \end{bmatrix} + \begin{bmatrix} -\alpha \\ 0_{k-1} \end{bmatrix}$$

$$= \begin{bmatrix} Y_j \\ X_j \end{bmatrix} + \begin{bmatrix} 0 & -\beta^T \\ 0_{k-1} & 0_{k-1}^T \end{bmatrix} \begin{bmatrix} Y_j \\ X_j \end{bmatrix} + \begin{bmatrix} -\alpha \\ 0_{k-1} \end{bmatrix}$$

$\checkmark x_1$ $\checkmark x_2$ $\checkmark x_1$ $\checkmark x_1$

$\Rightarrow \{Z_j\}_{j=1}^n$ son transf. bariénicas de los vect. aleatorios i.i.d. $\{Y_j\}_{j=1}^n$

$\therefore \{Z_j\}_{j=1}^n = \{U_j\}_{j=1}^n$ son i.i.d.

$$c) \{x_j U_j\}_{j=1}^n = \left\{ \begin{pmatrix} x_{j1} U_j \\ x_{j2} U_j \\ \vdots \\ x_{jm} U_j \\ \vdots \\ x_{j,k-1} U_j \end{pmatrix}_{j=1}^n \right\}$$

son vectores aleatorios i.i.d.

Notemos que $\begin{pmatrix} U_j \\ X_j \end{pmatrix}$

$$\begin{matrix} (K-1) \times K & K \times 1 & (K-1) \times 1 \\ \left[\begin{array}{cccc} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{array} \right] & \left[\begin{array}{c} U_j \\ X_{j1} \\ X_{j2} \\ \vdots \\ X_{j,K-1} \end{array} \right] = X_j & \left(\downarrow, \overrightarrow{0}_{K-1}^\top \right) \left[\begin{array}{c} U_j \\ X_j \end{array} \right] = U_j \end{matrix}$$

$$\Rightarrow X_j U_j = \begin{matrix} (K-1) \times K & K \times 1 & 1 \times K & K \times 1 \\ \left[\begin{array}{cccc} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{array} \right] & \left[\begin{array}{c} U_j \\ X_{j1} \\ X_{j2} \\ \vdots \\ X_{j,K-1} \end{array} \right] & \left(\downarrow, \overrightarrow{0}_{K-1}^\top \right) \left[\begin{array}{c} U_j \\ X_j \end{array} \right] \end{matrix}$$

$\Rightarrow \{X_j U_j\}_{j=1}^n$ son transfr. lineales del vector aleatorio iid $\begin{pmatrix} U_j \\ X_j \end{pmatrix}$

$$\therefore \{X_j U_j\}_{j=1}^n$$

ALTERNATIVAMENTE

6 6 6

$$\begin{aligned} & \underset{(K-1) \times K}{X_j} \underset{K \times 1}{Y_j} = X_j (Y_j - \underset{K \times K}{B^T} X_j - \alpha) \\ & = X_j Y_j - X_j B^T X_j - \alpha X_j \\ & = X_j Y_j - X_j (B^T X_j + \alpha) \end{aligned}$$

$$= \underbrace{\begin{bmatrix} X_{j,1} \\ X_{j,2} \\ \vdots \\ X_{j,K-1} \end{bmatrix}}_C Y_j + \underbrace{\begin{bmatrix} X_{j,1} \\ X_{j,2} \\ \vdots \\ X_{j,K-1} \end{bmatrix}}_A (-B^T X_j - \alpha)$$

$$-B^T X_j - \alpha = \begin{bmatrix} 0 & -B^T \end{bmatrix} \begin{bmatrix} Y_j \\ X_j \end{bmatrix} - \alpha \quad (\text{A})$$

$$(B) \quad X_j = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \end{bmatrix} \begin{bmatrix} Y_j \\ X_{j,1} \\ X_{j,2} \\ \vdots \\ X_{j,K-1} \end{bmatrix} = \begin{bmatrix} X_{j,1} \\ X_{j,2} \\ \vdots \\ X_{j,K-1} \end{bmatrix}$$

$$(C) \quad (1, 0_{K-1}^\top) \begin{bmatrix} Y_j \\ X_{j,1} \\ X_{j,2} \\ \vdots \\ X_{j,K-1} \end{bmatrix} = Y_j \quad (\text{C})$$

B

C

B

A

$$= \underbrace{\begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{bmatrix}}_{0_{K-1} \ I_{K-1}} \underbrace{\begin{bmatrix} Y_j \\ X_j \end{bmatrix}}_{1 \times K \ K \times 1} + \underbrace{\begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{bmatrix}}_{0_{K-1} \ I_{K-1}} \underbrace{\begin{bmatrix} Y_j \\ X_j \end{bmatrix}}_{1 \times K \ K \times 1} [0, -B^T] \begin{bmatrix} Y_j \\ X_j \end{bmatrix}$$

$\Rightarrow \{x_j, v_j\}_{j=1}^n$ son transf. borelianras de los vect. aleatorios $i, j \in \{Y_j\}_{j=1}^n$

$\therefore \{x_j, v_j\}_{j=1}^n$ son iid.

$$d) \text{ cov}(U_j, X_{im}) = 0 \quad j = 1, 2, \dots, n; \quad i = 1, 2, \dots, n; \quad i \neq j, \quad m = 1, 2, \dots, k-1$$

En clase se vio una proposición que postula que si $\{U_j\}_{j=1}^n$ son iid:

$$\Rightarrow \forall i, j \in \{1, 2, \dots, n\} \text{ con } i \neq j : \begin{cases} U_j \text{ y } U_i \\ U_j \text{ y } X_i \\ X_j \text{ y } U_i \\ X_j \text{ y } X_i \end{cases} \text{ son variables aleatorias independientes}$$

$$\Rightarrow \forall i, j \in \{1, 2, \dots, n\} \text{ con } i \neq j : \text{cov}(U_j, U_i) = 0_{1 \times 1} \quad \text{cov}(X_j, X_i) = 0_{(k-1) \times (k-1)}$$

$$\text{cov}(U_j, X_i) = 0_{1 \times (k-1)} \quad \text{cov}(X_j, U_i) = 0_{(k-1) \times 1}$$

Además, si $\text{cov}(U_j, X_i) = 0 \quad \forall i, j \in \{1, 2, \dots, n\} \text{ con } i \neq j$

$$\Rightarrow 0 = \text{cov}(U_j, X_i) = \text{cov}(U_j, \begin{bmatrix} X_{i1} \\ X_{i2} \\ \vdots \\ X_{in} \end{bmatrix}) = E \left[(U_j - E(U_j)) \begin{pmatrix} X_{i1} - E(X_{i1}) \\ X_{i2} - E(X_{i2}) \\ \vdots \\ X_{in} - E(X_{in}) \end{pmatrix}^T \right] =$$

$$= E \left[\begin{pmatrix} (U_j - E(U_j))(X_{i1} - E(X_{i1}))^T \\ (U_j - E(U_j))(X_{i2} - E(X_{i2}))^T \\ \vdots \\ (U_j - E(U_j))(X_{in} - E(X_{in}))^T \end{pmatrix} \right] = \begin{bmatrix} E[(U_j - E(U_j))(X_{i1} - E(X_{i1}))^T] \\ E[(U_j - E(U_j))(X_{i2} - E(X_{i2}))^T] \\ \vdots \\ E[(U_j - E(U_j))(X_{in} - E(X_{in}))^T] \end{bmatrix}^T = \begin{bmatrix} \text{cov}(U_j, X_{i1}) \\ \text{cov}(U_j, X_{i2}) \\ \vdots \\ \text{cov}(U_j, X_{in}) \end{bmatrix}^T = 0$$

$$\therefore \text{cov}(U_j, X_{im}) = 0 \quad \forall j, i \in \{1, 2, \dots, n\} \text{ con } i \neq j \text{ y } \forall m \in \{1, 2, \dots, k-1\}$$

NOTEMOS QUE:

ii) Demostrar:

$$E[\mathbf{x}' \mathbf{U}] = \mathbf{0}_{k \times 1}$$

$$\Leftrightarrow E[x_j U_j] = \mathbf{0}_{k \times 1} \quad j = 1, 2, \dots, n$$

$$\Leftrightarrow E(U_j) = 0 \quad y \quad E(\mathbf{x}_j U_j) = \mathbf{0}_{(k-1) \times 1} \quad j = 1, 2, \dots, n$$

$$\Leftrightarrow E(U_j) = 0 \quad y \quad E(x_{ji} U_j) = \mathbf{0}_{1 \times 1} \quad j = 1, 2, \dots, n; i = 1, 2, \dots, k-1$$

$$\Leftrightarrow E(U_j) = 0 \quad y \quad \text{cov}(\mathbf{x}_j, U_j) = \mathbf{0}_{(k-1) \times 1} \quad j = 1, 2, \dots, n$$

$$\Leftrightarrow E(U_j) = 0 \quad y \quad \text{cov}(x_{ji}, U_j) = 0 \quad j = 1, 2, \dots, n; i = 1, 2, \dots, k-1$$

$$= \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_{k-1} \end{bmatrix} U_1 + \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_{k-1} \end{bmatrix} U_2 + \dots + \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_{k-1} \end{bmatrix} U_n$$

$$= \begin{bmatrix} 1 \\ x_{1,1} \\ x_{1,2} \\ \vdots \\ x_{1,k-1} \end{bmatrix} U_1 + \begin{bmatrix} 1 \\ x_{2,1} \\ x_{2,2} \\ \vdots \\ x_{2,k-1} \end{bmatrix} U_2 + \dots + \begin{bmatrix} 1 \\ x_{n,1} \\ x_{n,2} \\ \vdots \\ x_{n,k-1} \end{bmatrix} U_n$$

$$= \begin{bmatrix} U_1 + U_2 + \dots + U_n \\ x_{1,1} U_1 + x_{2,1} U_2 + \dots + x_{n,1} U_n \\ \vdots \\ x_{1,k-1} U_1 + x_{2,k-1} U_2 + \dots + x_{n,k-1} U_n \end{bmatrix}$$

$$E[x' \mathbf{U}] = \mathbf{0}_{k \times 1} \Leftrightarrow E[x_j U_j] = \mathbf{0}_{k \times 1}$$

←

$$E[x' \mathbf{U}] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_j & \dots & x_n \end{pmatrix} \begin{pmatrix} U_1 \\ U_2 \\ \vdots \\ U_n \end{pmatrix} \right] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 \\ x_{1,1} & x_{2,1} & \dots & x_{n,1} \\ x_{1,2} & x_{2,2} & \dots & x_{n,2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1,k-1} & x_{2,k-1} & \dots & x_{n,k-1} \end{pmatrix} \begin{pmatrix} U_1 \\ U_2 \\ \vdots \\ U_n \end{pmatrix} \right]$$



$$\begin{aligned} &= E \left[\begin{array}{c} U_1 + U_2 + \dots + U_n \\ x_{1,1} U_1 + x_{2,1} U_2 + \dots + x_{n,1} U_n \\ x_{1,2} U_1 + x_{2,2} U_2 + \dots + x_{n,2} U_n \\ \vdots \\ x_{1,k-1} U_1 + x_{2,k-1} U_2 + \dots + x_{n,k-1} U_n \end{array} \right] \\ &\stackrel{?}{=} E \left[x_1 U_1 + x_2 U_2 + \dots + x_n U_n \right] \end{aligned}$$

hipótesis

$$= E[x_1 U_1] + E[x_2 U_2] + \dots + E[x_n U_n] = \sum_{j=1}^n E[x_j U_j] = 0$$

Por lo tanto \Rightarrow se cumple el resultado. ■

* $\{x_j U_j\}_{j=1}^n$ son iid por ser transformaciones de $\{(X_j U_j)\}_{j=1}^n$ y de $\{\left(\frac{U_j}{X_j}\right)\}_{j=1}^n$

$$E[X^T V] = 0_{K \times 1} \Leftrightarrow E[V_j] = 0 \quad \text{y} \quad E[X_j V_j] = 0_{(K-1) \times 1}, \quad j = 1, 2, \dots, n$$

\Leftarrow

$$E[X^T V] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 & \dots & 1 \\ X_1 & X_2 & \dots & X_j & \dots & X_n \end{pmatrix} \begin{pmatrix} V_1 \\ V_2 \\ \vdots \\ V_n \end{pmatrix} \right] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 \\ X_{11} & X_{21} & \dots & X_{n1} \\ X_{12} & X_{22} & \dots & X_{n2} \\ \vdots & \vdots & & \vdots \\ X_{1,K-1} & X_{2,K-1} & \dots & X_{n,K-1} \end{pmatrix} \begin{pmatrix} V_1 \\ V_2 \\ \vdots \\ V_n \end{pmatrix} \right]$$

$$= E \left[\begin{matrix} V_1 + V_2 + \dots + V_n \\ X_{11}V_1 + X_{21}V_2 + \dots + X_{n1}V_n \\ X_{12}V_1 + X_{22}V_2 + \dots + X_{n2}V_n \\ \vdots \\ X_{1,K-1}V_1 + X_{2,K-1}V_2 + \dots + X_{n,K-1}V_n \end{matrix} \right] = \left[\begin{matrix} E[V_1 + V_2 + \dots + V_n] \\ E[X_{11}V_1 + X_{21}V_2 + \dots + X_{n1}V_n] \\ E[X_{12}V_1 + X_{22}V_2 + \dots + X_{n2}V_n] \\ \vdots \\ E[X_{1,K-1}V_1 + X_{2,K-1}V_2 + \dots + X_{n,K-1}V_n] \end{matrix} \right]$$

$$= \left[\begin{matrix} \sum_{j=1}^n E(V_j) \\ \sum_{j=1}^n E(X_{j1}V_j) \\ \sum_{j=1}^n E[X_{j2}V_j] \\ \vdots \\ \sum_{j=1}^n X_{j,K-1}V_j \end{matrix} \right] = \left[\begin{matrix} \sum_{j=1}^n E(V_j) \\ \sum_{j=1}^n E(X_{j1}V_j) \\ \sum_{j=1}^n E(X_{j2}V_j) \\ \vdots \\ \sum_{j=1}^n X_{j,K-1}V_j \end{matrix} \right] \stackrel{\text{hipótesis}}{=} \begin{bmatrix} 0 \\ 0_{K-1} \end{bmatrix} = 0_{K \times 1}$$

Por lo tanto



se tiene al vector.



$$E[X^T V] = 0_{k \times 1} \iff E[V_j] = 0 \quad \Rightarrow \quad E(X_{j,i} V_j) = 0_{1 \times 1} ; \quad j=1, 2, \dots, n ; \quad i=1, 2, \dots, k-1$$

\Leftarrow

$$E[X^T V] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 & \dots & 1 \\ X_1 & X_2 & \dots & X_j & \dots & X_n \end{pmatrix}_{k \times n} \begin{pmatrix} V_1 \\ V_2 \\ \vdots \\ V_n \end{pmatrix}_{n \times 1} \right] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 \\ X_{11} & X_{21} & \dots & X_{n1} \\ X_{12} & X_{22} & \dots & X_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ X_{1,k-1} & X_{2,k-1} & \dots & X_{n,k-1} \end{pmatrix}_{k \times n} \begin{pmatrix} V_1 \\ V_2 \\ \vdots \\ V_n \end{pmatrix}_{n \times 1} \right]$$

$$= E \left[\begin{matrix} V_1 + V_2 + \dots + V_n \\ X_{11}V_1 + X_{21}V_2 + \dots + X_{n1}V_n \\ X_{12}V_1 + X_{22}V_2 + \dots + X_{n2}V_n \\ \vdots \\ X_{1,k-1}V_1 + X_{2,k-1}V_2 + \dots + X_{n,k-1}V_n \end{matrix} \right] = \left[\begin{matrix} E[V_1 + V_2 + \dots + V_n] \\ E[X_{11}V_1 + X_{21}V_2 + \dots + X_{n1}V_n] \\ E[X_{12}V_1 + X_{22}V_2 + \dots + X_{n2}V_n] \\ \vdots \\ E[X_{1,k-1}V_1 + X_{2,k-1}V_2 + \dots + X_{n,k-1}V_n] \end{matrix} \right]$$

$$= \left[\begin{matrix} \sum_{j=1}^n E(V_j) \\ \sum_{j=1}^n E(X_{j,1}V_j) \\ \sum_{j=1}^n E[X_{j,2}V_j] \\ \vdots \\ \sum_{j=1}^n X_{j,k-1}V_j \end{matrix} \right] = \begin{pmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} = 0_{k \times 1}$$

nun ist es

Peru \Rightarrow se lee al revés \blacksquare

$$E[X^T U] = 0_{K \times 1} \Leftrightarrow E(U_j) = 0 \quad \text{y} \quad \text{cov}(X_j, U_j) = 0_{(K-1) \times 1} \quad j=1, 2, \dots, n$$

←

$$E[X^T U] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 & \dots & 1 \\ X_1 & X_2 & \dots & X_j & \dots & X_n \end{pmatrix} \begin{pmatrix} U_1 \\ U_2 \\ \vdots \\ U_n \end{pmatrix} \right] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 \\ X_{11} & X_{21} & \dots & X_{n1} \\ X_{12} & X_{22} & \dots & X_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ X_{1,K-1} & X_{2,K-1} & \dots & X_{n,K-1} \end{pmatrix} \begin{pmatrix} U_1 \\ U_2 \\ \vdots \\ U_n \end{pmatrix} \right]$$

$$= E \left[\begin{matrix} U_1 + U_2 + \dots + U_n \\ X_{11}U_1 + X_{21}U_2 + \dots + X_{n1}U_n \\ X_{12}U_1 + X_{22}U_2 + \dots + X_{n2}U_n \\ \vdots \\ X_{1,K-1}U_1 + X_{2,K-1}U_2 + \dots + X_{n,K-1}U_n \end{matrix} \right] = E \left[\begin{matrix} \sum_{j=1}^n (U_j) \\ \sum_{j=1}^n X_{j1}U_j \\ \sum_{j=1}^n X_{j2}U_j \\ \vdots \\ \sum_{j=1}^n X_{j,K-1}U_j \end{matrix} \right] = E \left[\begin{matrix} \sum_{j=1}^n (U_j) \\ \sum_{j=1}^n X_j U_j \end{matrix} \right]$$

$$= \left[\begin{matrix} \sum_{j=1}^n E(U_j) \\ \sum_{j=1}^n E[X_j U_j] \end{matrix} \right] = \left[\begin{matrix} \sum_{j=1}^n E(U_j) \\ \sum_{j=1}^n \text{cov}(X_j, U_j) + E[X_j] E[U_j] \end{matrix} \right]$$

hipótesis

$$= \begin{bmatrix} 0 \\ 0 \end{bmatrix}_{(K-1) \times 1}$$

$$= 0_{K \times 1}$$

Para \Rightarrow se lee al revés



$$E[X^T V] = 0_{k \times 1} \Leftrightarrow E(V_j) = 0 \quad \text{y} \quad \text{cov}(X_{ji}, V_j) = 0 \quad j=1, 2, \dots, n; i=1, 2, \dots, k-1$$

⇐

$$E[X^T V] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 & \dots & 1 \\ X_1 & X_2 & \dots & X_j & \dots & X_n \end{pmatrix} \begin{pmatrix} V_1 \\ V_2 \\ \vdots \\ V_n \end{pmatrix} \right] = E \left[\begin{pmatrix} 1 & 1 & \dots & 1 \\ X_{11} & X_{21} & \dots & X_{n1} \\ X_{12} & X_{22} & \dots & X_{n2} \\ \vdots & \vdots & & \vdots \\ X_{1,k-1} & X_{2,k-1} & \dots & X_{n,k-1} \end{pmatrix} \begin{pmatrix} V_1 \\ V_2 \\ \vdots \\ V_n \end{pmatrix} \right]$$

$$= E \left[\begin{matrix} V_1 + V_2 + \dots + V_n \\ X_{11}V_1 + X_{21}V_2 + \dots + X_{n1}V_n \\ X_{12}V_1 + X_{22}V_2 + \dots + X_{n2}V_n \\ \vdots \\ X_{1,k-1}V_1 + X_{2,k-1}V_2 + \dots + X_{n,k-1}V_n \end{matrix} \right]$$

$$= E \left[\begin{matrix} \sum_{j=1}^n (V_j) \\ \sum_{j=1}^n X_{j1}V_j \\ \sum_{j=1}^n X_{j2}V_j \\ \vdots \\ \sum_{j=1}^n X_{j,k-1}V_j \end{matrix} \right] = E \left[\begin{matrix} \sum_{j=1}^n (V_j) \\ E \left[\sum_{j=1}^n X_{j1}V_j \right] \\ E \left[\sum_{j=1}^n X_{j2}V_j \right] \\ \vdots \\ E \left[\sum_{j=1}^n X_{j,k-1}V_j \right] \end{matrix} \right]$$

$$\begin{aligned} & \left[\begin{matrix} \sum_{j=1}^n E[V_j] \\ \sum_{j=1}^n E[X_{j1}V_j] \\ \sum_{j=1}^n E[X_{j2}V_j] \\ \vdots \\ \sum_{j=1}^n E[X_{j,k-1}V_j] \end{matrix} \right] = \left[\begin{matrix} \sum_{j=1}^n E(V_j) \\ \sum_{j=1}^n \cancel{\text{cov}(X_{ji}, V_j)} + E(X_{ji})E(V_j) \\ \sum_{j=1}^n \cancel{\text{cov}(X_{j2}, V_j)} + E(X_{j2})E(V_j) \\ \vdots \\ \sum_{j=1}^n \cancel{\text{cov}(X_{j,k-1}, V_j)} + E(X_{j,k-1})E(V_j) \end{matrix} \right] \\ & \qquad \qquad \qquad \text{hipótesis} \end{aligned}$$

Para \Rightarrow se lee al revés



5. Estudiar las sección 2-2 Deriving the Ordinary Least Squares Estimates del capítulo 2 de Wooldridge J.M., Introductory Econometrics: A Modern Approach, 5th, 6th or 7th Edition, South-Western CENGAGE Learning.