

ECONOMETRIA I
TAREA 17
MAESTRIA EN ECONOMIA, 2023-2025
EL COLEGIO DE MEXICO

Profr. Eneas A. Caldiño García
Entrega: 13 de mayo de 2024

1. i) Generar (usando algún paquete econométrico) una muestra $\{X_i\}_{i=1}^{260}$ de v.a.s i.i.d. (Usar cualquier distribución que se quiera).

ii) Generar una muestra $\{U_i\}_{i=1}^{260}$ de v.a.s i.i.d. donde $U_i \sim N_2(0, 0.4)$, $i = 1, 2, \dots, 260$ tal que U_i y X_j son independientes $\forall i \neq j, i, j \in \{1, 2, \dots, 260\}$.

iii) Usando los datos obtenidos en i) y ii), generar la muestra $\{Y_i\}_{i=1}^{120}$ donde

$$Y_i = 0.6 + 0.5X_i + U_i, \quad i = 1, 2, \dots, 120$$

iv) Usando los datos obtenidos en i) y ii), generar la muestra $\{Y_i\}_{i=121}^{260}$ donde

$$Y_i = 0.9 + 0.3X_i + U_i, \quad i = 121, \dots, 260$$

Con los datos obtenidos en i), iii) y iv) $\left\{ \begin{pmatrix} Y_i \\ X_i \end{pmatrix} \right\}_{i=1}^{260}$ se considera el modelo:

$$\begin{cases} Y_i = \alpha_1 + \beta_1 X_i + U_i & E[Y_i | 1, X_i] = 0, \quad i = 1, \dots, 120 \\ Y_i = \alpha_2 + \beta_2 X_i + V_i & E[Y_i | 1, X_i] = 0, \quad i = 121, \dots, 260 \end{cases}$$

v) Probar la hipótesis

$$H_0: \begin{pmatrix} \alpha_1 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} \alpha_2 \\ \beta_2 \end{pmatrix} \quad (\text{i.e. no hay cambio estructural})$$

contra la alternativa:

$$H_1: \begin{pmatrix} \alpha_1 \\ \beta_1 \end{pmatrix} \neq \begin{pmatrix} \alpha_2 \\ \beta_2 \end{pmatrix}$$

con nivel de significancia $\alpha = 0.05$, calculando y usando los estadísticos:

$$a) \frac{(\hat{\mathbf{Rb}}_{MCU} - \mathbf{r})' [\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1} (\hat{\mathbf{Rb}}_{MCU} - \mathbf{r})}{m \hat{\sigma}_{uMCU}^2} \sim F_{m, n-k}$$

donde m = número de restricciones lineales

n = tamaño de la muestra (número total de observaciones)

k = dimensión del vector $\mathbf{b} = \begin{pmatrix} \alpha_1 & \beta_1 & \alpha_2 & \beta_2 \end{pmatrix}'$.

$$b) \frac{\hat{\mathbf{U}}'_{MCR} \hat{\mathbf{U}}_{MCR} - \hat{\mathbf{U}}'_{MCU} \hat{\mathbf{U}}_{MCU}}{m \frac{1}{n-k} \hat{\mathbf{U}}'_{MCU} \hat{\mathbf{U}}_{MCU}} \sim F_{m, n-k}$$

$$c) \frac{(\hat{\mathbf{b}}_{MCR} - \hat{\mathbf{b}}_{MCU})' \mathbf{X}'\mathbf{X}(\hat{\mathbf{b}}_{MCR} - \hat{\mathbf{b}}_{MCU})}{m \frac{1}{n-k} (\hat{\mathbf{U}}'_{MCU} \hat{\mathbf{U}}_{MCU})} \sim F_{m, n-k}$$

2. Ver Wooldridge, J. M., *Introductory Econometrics: A Modern Approach*. 6th Edition. South-Western. CENGAGE Learning. Ejercicio C6, pág. 238.

$$sleep = \alpha + \beta_1 totwrk + \beta_2 educ + \beta_3 age + \beta_4 age^2 + \beta_5 yngkid + u$$

i) Con un nivel de confianza del 5% probar la hipótesis de que no hay cambio estructural, i.e. para mujeres y hombres los 6 parámetros $\alpha, \beta_1, \dots, \beta_5$ son iguales, calculando y usando los estadísticos:

$$a) \frac{(\hat{\mathbf{Rb}}_{MCU} - \mathbf{r})' [\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1} (\hat{\mathbf{Rb}}_{MCU} - \mathbf{r})}{m \hat{\sigma}_{uMCU}^2} \sim F_{m, n-k}$$

donde m = número de restricciones lineales

n = tamaño de la muestra (número total de observaciones)

k = dimensión del vector $\mathbf{b} = \begin{pmatrix} \alpha_1 & \beta_1 & \alpha_2 & \beta_2 \end{pmatrix}'$.

$$b) \frac{\hat{\mathbf{U}}'_{\text{MCR}} \hat{\mathbf{U}}_{\text{MCR}} - \hat{\mathbf{U}}'_{\text{MCU}} \hat{\mathbf{U}}_{\text{MCU}}}{m \frac{1}{n-k} \hat{\mathbf{U}}'_{\text{MCU}} \hat{\mathbf{U}}_{\text{MCU}}} \sim F_{m, n-k}$$

$$c) \frac{(\hat{\mathbf{b}}_{\text{MCR}} - \hat{\mathbf{b}}_{\text{MCU}})' \mathbf{x}' \mathbf{x} (\hat{\mathbf{b}}_{\text{MCR}} - \hat{\mathbf{b}}_{\text{MCU}})}{m \frac{1}{n-k} (\hat{\mathbf{U}}'_{\text{MCU}} \hat{\mathbf{U}}_{\text{MCU}})} \sim F_{m, n-k}$$

$$3. \left\{ \begin{pmatrix} Y_j \\ \mathbf{x}_j \end{pmatrix} \right\}_{j=1}^n \text{ vectores aleatorios de dimensión } k, \text{ i.i.d.}$$

$$\mathbf{Y} = \mathbf{X}\mathbf{b} + \mathbf{U} \quad E(\mathbf{U}) = \mathbf{0}_{n \times 1}$$

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{x}_j = \begin{pmatrix} X_{j1} \\ X_{j2} \\ \vdots \\ X_{j, k-1} \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & \mathbf{x}'_1 \\ 1 & \mathbf{x}'_2 \\ \vdots & \vdots \\ 1 & \mathbf{x}'_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1, k-1} \\ 1 & X_{21} & X_{22} & \cdots & X_{2, k-1} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{n, k-1} \end{pmatrix}$$

$$\mathbf{b} = \begin{pmatrix} \alpha \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_{k-1} \end{pmatrix}, \quad \mathbf{U} = \begin{pmatrix} U_1 \\ U_2 \\ \vdots \\ U_n \end{pmatrix}$$

Demostrar que si en la ecuación

$$Y_j = \alpha + \beta_1 X_{j1} + \beta_2 X_{j2} + \dots + \beta_i X_{ji} + \dots + \beta_{k-1} X_{j, k-1} + U_j \quad j = 1, 2, \dots, n$$

existe al menos una variable explicativa endógena, i.e. para alguna $i \in \{1, 2, \dots, k-1\}$, $\text{cov}(X_{ji}, U_j) \neq 0$, entonces

$$i) E[\mathbf{x}_j \mathbf{U}_j] \neq \mathbf{0}_{(k-1) \times 1}$$

$$\text{ii) } E[\mathbf{x}'\mathbf{U}] \neq \mathbf{0}_{k \times 1}$$

$$\text{iii) } E[\mathbf{U}|\mathbf{x}] \neq \mathbf{0}_{n \times 1}$$

4. Cálculo del sesgo de $\hat{\mathbf{b}}_{\text{MCO}}$ cuando $E[\mathbf{x}'\mathbf{U}] \neq \mathbf{0}$ (i.e. cuando hay al menos una variable endógena, $\text{cov}(X_{jm}, U_j) \neq 0$, para alguna $m \in \{1, 2, \dots, k-1\}$).

$$\left\{ \begin{pmatrix} Y_j \\ \mathbf{x}_j \end{pmatrix} \right\}_{j=1}^{\infty} \quad \text{vectores aleatorios de dimensión } k \text{ i.i.d.}$$

$$\mathbf{y}^n = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{x}^n = \begin{pmatrix} 1 & \mathbf{x}'_1 \\ 1 & \mathbf{x}'_2 \\ \vdots & \vdots \\ 1 & \mathbf{x}'_n \end{pmatrix}, \quad \mathbf{U}^n = \begin{pmatrix} U_1 \\ U_2 \\ \vdots \\ U_n \end{pmatrix}$$

$$\mathbf{y}^n = \mathbf{x}^n \mathbf{b} + \mathbf{U}^n \quad E[\mathbf{x}_j U_j] \neq \mathbf{0}_{k \times 1} \quad (\text{i.e. } E[\mathbf{x}^n, \mathbf{U}^n] \neq \mathbf{0}_{k \times 1})$$

$$E(\mathbf{U}^n) = \mathbf{0}$$

$$\text{Prob}[\text{rango}(\mathbf{x}^n_{n \times k}) = k] = 1 \quad (\text{no multicolinealidad perfecta})$$

$$E(\mathbf{x}_j) = \mu_x < \infty \quad \text{y} \quad E(\mathbf{x}_j \mathbf{x}'_j) = \Delta_x < \infty$$

$$\hat{\mathbf{b}}^n_{\text{MCO}} = (\mathbf{x}^n, \mathbf{x}^n)^{-1} \mathbf{x}^n, \mathbf{y} = \mathbf{b} + \left(\frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}'_j \right)^{-1} \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j U_j$$

$$\text{donde } \mathbf{x}_j = \begin{pmatrix} 1 \\ \mathbf{x}_j \end{pmatrix}_{k \times 1}.$$

Demostrar:

$$\text{i) } E[\hat{\mathbf{b}}^n_{\text{MCO}} | \mathbf{x}^n] = \mathbf{b} + (\mathbf{x}^n, \mathbf{x}^n)^{-1} \mathbf{x}^n, E[\mathbf{U}^n | \mathbf{x}^n]$$

(i.e. $\hat{\mathbf{b}}^n_{\text{MCO}}$ es estimador condicionalmente sesgado).

$$\text{ii) } E(\hat{\mathbf{b}}^n_{\text{MCO}}) = \mathbf{b} + E[(\mathbf{x}^n, \mathbf{x}^n)^{-1} \mathbf{x}^n, E[\mathbf{U}^n | \mathbf{x}^n]]$$

(i.e. $\hat{\mathbf{b}}_{\text{MCO}}$ es estimador incondicionalmente sesgado).